

Máster en Finanzas Cuantitativas

UNED — Formación Permanente

**Differential Machine Learning para la valoración y
cobertura de una opción asiática sobre capacidad de
cómputo**

Aplicación al precio por GPU-hora bajo dinámica Log-OU

Autor: David Martín Gómez

Edición 2025/2026

Septiembre de 2026

Resumen

Este Trabajo Fin de Máster evalúa si *Differential Machine Learning* (DML) mejora, frente a un MLP convencional, la valoración y especialmente la estimación de Delta de una opción asiática aritmética sobre capacidad de cómputo. Como referencia empírica se utiliza una serie diaria de precios de alquiler de NVIDIA H100 y evidencia descriptiva complementaria del mercado chino. La dinámica física se representa mediante un proceso Log-Ornstein–Uhlenbeck y la valoración se realiza bajo una ley de pricing modelizada. Los precios y sensibilidades de referencia se generan mediante Randomized Quasi-Monte Carlo y estimación pathwise de Delta. MLP y DML comparten arquitectura, muestras y protocolo de entrenamiento, y se comparan en cuatro tamaños muestrales y cinco semillas emparejadas.

Con 65 536 estados de entrenamiento, DML reduce el RMSE de precio en test de 0,001624 a 0,001516, aunque el MLP obtiene un MAE ligeramente inferior. La diferencia es mucho mayor en Delta: el RMSE disminuye de 0,008528 a 0,001817 y el MAE de 0,001234 a 0,000216. Esta mejora se transmite a la cobertura local: ante un shock del 1 %, DML obtiene un RMSE de $1,058 \times 10^{-6}$ frente a $6,688 \times 10^{-6}$ para MLP y $1,355 \times 10^{-4}$ sin cobertura. En la cobertura dinámica con forwards modelizados, DML mejora sustancialmente al MLP, pero unas pocas trayectorias extremas impiden que domine a la posición sin cobertura en RMSE agregado.

Los resultados muestran que la supervisión diferencial mejora de forma robusta el aprendizaje de sensibilidades y su utilidad local para gestión del riesgo, pero también que una Greek más precisa no garantiza por sí sola una cobertura dinámica superior.

Palabras clave: Differential Machine Learning; opciones asiáticas; capacidad de cómputo; Randomized Quasi-Monte Carlo; Delta; cobertura; Log-OU.

Abstract

This Master’s Thesis evaluates whether *Differential Machine Learning* (DML) improves, relative to a conventional MLP, the valuation and especially the Delta estimation of a fixed-strike arithmetic Asian option written on compute capacity. A daily NVIDIA H100 rental-price series is used as the main empirical reference, complemented by descriptive evidence from the Chinese market. Physical price dynamics are represented by a Log-Ornstein–Uhlenbeck process, while valuation is performed under a modelled pricing law. Reference prices and sensitivities are generated using Randomized Quasi-Monte Carlo and a pathwise Delta estimator. MLP and DML share the same architecture, samples and training protocol, and are compared across four training-set sizes and five paired seeds.

With 65 536 training states, DML reduces test price RMSE from 0.001624 to 0.001516, although the MLP achieves a slightly lower MAE. The difference is substantially larger for Delta: RMSE falls from 0.008528 to 0.001817 and MAE from 0.001234 to 0.000216. This improvement carries over to local hedging: for a 1% spot shock, DML attains an RMSE of 1.058×10^{-6} versus 6.688×10^{-6} for the MLP and 1.355×10^{-4} without hedging. In the dynamic hedge using model-implied compute forwards, DML strongly improves on the MLP, but a small number of extreme paths prevents it from outperforming the unhedged position in aggregate RMSE.

The results show that differential supervision robustly improves sensitivity learning and its local risk-management value, while also demonstrating that a more accurate Greek is not by itself sufficient to guarantee superior dynamic hedging performance.

Keywords: Differential Machine Learning; Asian options; compute capacity; Randomized Quasi-Monte Carlo; Delta; hedging; Log-OU.

Índice general

Resumen	II
Abstract	III
1. Introducción	1
1.1. Contexto y motivación	1
1.2. Problema de investigación	2
1.3. Objetivo general y objetivos específicos	2
1.4. Contribuciones del trabajo	3
1.5. Estructura del documento	4
2. Revisión de la literatura y marco conceptual	5
2.1. Derivados sobre activos no almacenables	5
2.2. Valoración de opciones asiáticas	6
2.3. Modelos de commodities y reversión a la media	6
2.4. Monte Carlo y Randomized Quasi-Monte Carlo	8
2.5. Machine Learning para pricing	8
2.6. Differential Machine Learning	9
2.7. Cobertura y evaluación económica	10
2.8. Posicionamiento y aportación del TFM	11
3. Datos y mercado de capacidad de cómputo	12
3.1. Capacidad de cómputo como activo económico	12
3.2. Mercado de alquiler de GPU	12
3.3. Ornn Compute Price Index	12
3.4. SMM y el mercado chino de capacidad de cómputo	13
3.5. Selección del H100 como subyacente principal	14
3.6. Tratamiento de las series y construcción de variables	14
3.7. Comparación descriptiva entre el mercado global y chino	15
3.8. Limitaciones de los datos	16
4. Metodología	18
4.1. Definición del contrato asiático	18
4.2. Problema de valoración y medida de valoración	18
4.3. Geometric Brownian Motion como benchmark	19
4.4. Modelo Log-OU y reversión a la media	20
4.5. Calibración física y construcción del dominio paramétrico	20

4.6. Randomized Quasi-Monte Carlo	21
4.7. Estimación pathwise de Delta	22
4.8. Construcción del conjunto de datos sintético	23
4.9. MLP supervisado únicamente por precios	24
4.10. Differential Machine Learning	25
4.11. Selección de hiperparámetros y protocolo de congelación	26
4.12. Validación numérica, consistencia y control de leakage	27
4.13. Diseños de cobertura y evaluación económica	28
5. Resultados	30
5.1. Evidencia de reversión a la media y calibración del Log-OU	30
5.2. Resultados de valoración: MLP frente a DML	31
5.3. Precisión de Delta y eficiencia muestral	32
5.4. Errores extremos de precio y Delta	33
5.5. Efecto de las fronteras de fixing	34
5.6. Cobertura local: transmisión económica de la mejora en Delta	35
5.7. Cobertura dinámica con forwards	36
5.8. Concentración del error en las colas	38
5.9. Discusión conjunta y robustez	39
6. Conclusiones	40
6.1. Síntesis de los resultados principales	40
6.2. Respuesta a las preguntas de investigación	41
6.3. Implicaciones financieras y aportación	41
6.4. Limitaciones	42
6.5. Líneas futuras de investigación	43
Declaración de uso de herramientas de inteligencia artificial	45
Referencias	46

Índice de figuras

3.1. Evolución de los precios de alquiler por GPU en Ornn durante la muestra analizada. Panel extraído el 27/08/2026.	14
3.2. Evolución normalizada del precio H100: Ornn y SMM. Muestras congeladas el 26/08/2026.	16
5.1. RMSE de Delta en test según el tamaño del conjunto de entrenamiento.	33
5.2. Error absoluto medio de Delta según la distancia a la frontera de fixing más próxima.	35
5.3. RMSE de Delta frente al benchmark RQMC según el número de fixings futuros en la cobertura dinámica.	37
5.4. Concentración del error cuadrático terminal en las trayectorias extremas.	38

Índice de tablas

2.1. Comparación conceptual entre GBM y Log-OU	7
4.1. Dominio del experimento sintético Log-OU.	23
4.2. Configuración neuronal compartida por MLP y DML.	26
5.1. Calibración física del modelo Log-OU sobre Ormn H100.	31
5.2. Sensibilidad bootstrap de los parámetros Log-OU.	31
5.3. Error de valoración en el conjunto de test	32
5.4. Error de Delta en el conjunto de test	32
5.5. Colas del error absoluto de precio y Delta en test, $N_{\text{train}} = 65\,536$	33
5.6. Concentración de los 50 mayores errores de Delta de DML alrededor de fronteras de fixing	34
5.7. Error absoluto medio de Delta según distancia a una frontera de fixing	35
5.8. RMSE de cobertura local según magnitud del shock	36
5.9. Distribución del error terminal en la cobertura dinámica	36
5.10. Síntesis de los principales resultados de la configuración final	39

1. Introducción

1.1. Contexto y motivación

La capacidad de cómputo se ha convertido en un input económico relevante para el desarrollo y despliegue de sistemas modernos de inteligencia artificial. El aumento de los recursos computacionales disponibles ha acompañado la expansión del *deep learning* y de los modelos de gran escala (Sevilla et al., 2022). Para las empresas que no mantienen infraestructura propia, una parte de esta capacidad se adquiere mediante servicios de *cloud computing* y plataformas especializadas, donde el coste se expresa habitualmente por GPU-hora. La literatura sobre mercados de cloud ha analizado problemas de asignación, contratación y pricing dinámico de estos recursos (Li et al., 2016; Wu et al., 2019; Xu & Li, 2013).

Desde la perspectiva de gestión del riesgo, una empresa con necesidades recurrentes de cómputo no está expuesta sólo al precio observado en una fecha concreta, sino al coste medio pagado durante un horizonte. Esta característica motiva el uso de una opción asiática aritmética, cuyo payoff depende del promedio de una secuencia de precios. Para N fechas de fixing $t_1, \dots, t_N$, el contrato considerado es

$$H_T = \left(\frac{1}{N} \sum_{i=1}^N P_{t_i} - K \right)^+, \quad (1.1)$$

donde P_t representa el precio por GPU-hora y K el strike. El contrato se interpreta como un instrumento hipotético de cobertura del coste medio de capacidad, no como evidencia de que exista ya un mercado líquido y completo de derivados sobre compute. En 2026 se anunciaron iniciativas dirigidas a desarrollar futuros referenciados a índices de alquiler de GPU, pero la historia disponible todavía no permite tratar este mercado como una estructura madura de derivados (CME Group, 2026).

El problema presenta además una dimensión computacional. La opción es dependiente de trayectoria y su valoración de referencia se obtiene mediante simulación. Esto hace natural estudiar redes neuronales como *surrogates* de la función de pricing y, en particular, si incorporar información diferencial durante el entrenamiento mejora la aproximación de la sensibilidad relevante para cobertura. Differential Machine Learning (DML) extiende el aprendizaje supervisado convencional utilizando simultáneamente etiquetas de valor y de derivadas (Huge & Savine, 2020). El presente TFM combina esta idea con un entorno de valoración RQMC y una dinámica Log-Ornstein–Uhlenbeck para estudiar no sólo la precisión numérica del precio y la Delta, sino también su utilidad económica en cobertura.

1.2. Problema de investigación

El trabajo combina dos preguntas. La primera es numérica: si un MLP convencional y DML, comparados bajo la misma arquitectura y protocolo, aproximan de forma diferente el precio y la Delta de una opción asiática. La segunda es financiera: si una mejora en la estimación de la Delta se traduce efectivamente en una reducción del error de cobertura.

El motor RQMC genera, para cada estado $\mathbf{x}$, una referencia de precio $V(\mathbf{x})$ y una sensibilidad

$$\Delta(\mathbf{x}) = \frac{\partial V(\mathbf{x})}{\partial P}. \quad (1.2)$$

El MLP convencional aprende a partir de pares $(\mathbf{x}_i, V_i)$, mientras que DML utiliza además la etiqueta diferencial Δ_i . La comparación se diseña para aislar esta diferencia y evitar que una eventual ventaja se deba a arquitecturas o procedimientos de selección distintos.

La **pregunta principal de investigación** es:

¿En qué medida la incorporación de información diferencial mediante Differential Machine Learning mejora, respecto a un MLP convencional, la aproximación del precio y especialmente de la Delta de una opción asiática aritmética sobre capacidad de cómputo?

Como complemento, se plantea una segunda pregunta de naturaleza económica:

¿Se traduce una estimación más precisa de la Delta en una reducción efectiva del error de cobertura y se mantiene dicha ventaja cuando se pasa de una perturbación local a una estrategia dinámica con rebalanceo discreto?

Estas preguntas se evalúan separando precisión de pricing, precisión de Delta, eficiencia muestral y desempeño de cobertura. En particular, no se presupone que una mejora en la sensibilidad implique automáticamente una mejora uniforme del precio ni del hedge dinámico.

1.3. Objetivo general y objetivos específicos

El objetivo general del TFM es:

evaluar si la incorporación de información diferencial mediante Differential Machine Learning mejora, frente a un MLP convencional, la aproximación del precio y especialmente de la Delta de una opción asiática aritmética sobre capacidad de cómputo, y analizar en qué medida dicha mejora se traduce en una reducción efectiva del riesgo de cobertura.

Para alcanzarlo se establecen los siguientes objetivos específicos:

1. Caracterizar la serie observable de precios de alquiler H100 y evaluar si su comportamiento es compatible con una dinámica de reversión a la media.
2. Construir un entorno reproducible de valoración de una opción asiática aritmética mediante Log-OU y Randomized Quasi-Monte Carlo.
3. Generar y validar etiquetas de precio y Delta, contrastando la sensibilidad pathwise mediante diferencias finitas y controles numéricos independientes.
4. Comparar de forma homogénea un MLP convencional y DML sobre tamaños de entrenamiento anidados y múltiples semillas, manteniendo separado el proceso de selección de la evaluación final.
5. Analizar pricing, Delta, eficiencia muestral, errores extremos y sensibilidad alrededor de las fronteras de fixing.
6. Evaluar la utilidad económica de las sensibilidades mediante una cobertura local y una estrategia dinámica con forward modelizado.

1.4. Contribuciones del trabajo

La aportación del TFM no consiste en proponer un nuevo modelo estocástico, un nuevo algoritmo RQMC o una arquitectura neuronal original. Su contribución es integrar herramientas consolidadas dentro de un experimento financiero controlado y reproducible.

En primer lugar, se formula el precio por GPU-hora como una exposición económica al coste de un servicio de cómputo y se distingue explícitamente entre la GPU física, almacenable como bien de capital, y la GPU-hora, que representa capacidad temporal. Sobre esta exposición se define una opción asiática aritmética como instrumento hipotético de gestión del riesgo del coste medio.

En segundo lugar, se construye un entorno de pricing y sensibilidades que combina una dinámica Log-OU, integración RQMC y una Delta pathwise validada mediante diferencias finitas. El diseño separa los conjuntos utilizados para entrenamiento, selección y evaluación y conserva una muestra de referencia de mayor precisión.

En tercer lugar, se realiza una comparación homogénea entre MLP y DML. Ambos modelos comparten arquitectura, datos y protocolo de entrenamiento; la diferencia sustantiva es el uso de supervisión diferencial. Esta estructura permite atribuir con mayor claridad las diferencias observadas al tratamiento de la información de Delta.

En cuarto lugar, el análisis no se limita a métricas de predicción. La calidad de la Delta se traslada a dos pruebas de cobertura: una perturbación local, que mide su capacidad para neutralizar pequeñas variaciones del subyacente, y un experimento dinámico con rebalanceo discreto mediante un forward modelizado. De este modo se distingue entre precisión estadística de una Greek y desempeño económico de un sistema de cobertura.

Finalmente, el trabajo delimita expresamente su alcance. La serie H100 disponible es corta, la medida de valoración es modelizada y el mercado de derivados sobre compute es emergen-

te. Por ello, las conclusiones se interpretan como evidencia interna sobre el marco experimental propuesto y no como validación de precios negociables observados en un mercado completo.

1.5. Estructura del documento

El Capítulo 2 revisa la literatura sobre activos no almacenables, opciones asiáticas, reversión a la media, RQMC, redes neuronales para pricing, DML y cobertura. El Capítulo 3 documenta las fuentes de datos, la selección del H100 y las limitaciones de las referencias globales y chinas. El Capítulo 4 presenta la metodología: contrato, Log-OU, generación de etiquetas, MLP, DML y experimentos de cobertura. El Capítulo 5 analiza los resultados de pricing, Delta, eficiencia muestral, errores extremos, fixings y cobertura. Finalmente, el Capítulo 6 responde a las preguntas de investigación, resume las implicaciones financieras y expone las principales limitaciones y extensiones.

2. Revisión de la literatura y marco conceptual

2.1. Derivados sobre activos no almacenables

La valoración de derivados sobre activos físicos depende de si el subyacente puede almacenarse y trasladarse entre periodos. En commodities almacenables, la relación entre spot y forward puede apoyarse en argumentos de *cash-and-carry*, en los que intervienen costes de almacenamiento y *convenience yield* Schwartz, 1997. Esta lógica se debilita cuando el objeto económico es perecedero o no puede inventariarse. La electricidad constituye un precedente útil: su limitada almacenabilidad hace que la estructura forward dependa en mayor medida de expectativas sobre oferta y demanda, estacionalidad y primas por riesgo Lucia y Schwartz, 2002.

Esta distinción es central en el presente TFM. El subyacente económico no es la GPU como activo de capital, sino la *GPU-hora* como servicio de capacidad durante un intervalo temporal. El hardware puede adquirirse, mantenerse y revenderse; una unidad de capacidad no utilizada en un periodo, en cambio, no puede conservarse y venderse posteriormente como esa misma unidad de servicio. La literatura sobre *cloud computing* adopta una interpretación similar al analizar recursos computacionales perecederos, pricing dinámico y mecanismos *on-demand* o *spot* Li et al., 2016; Wu et al., 2019; Xu y Li, 2013.

La analogía con la electricidad es estructural, no literal. La capacidad de cómputo presenta heterogeneidad por hardware, localización y calidad del servicio, y puede sustituirse parcialmente entre proveedores, regiones o fechas Li et al., 2016. Por ello, el término “no almacenable” se utiliza aquí en sentido económico: la unidad temporal de servicio no puede inventariarse, sin afirmar que el hardware carezca de valor de almacenamiento ni que el mercado de compute sea equivalente a un mercado eléctrico.

Esta característica afecta también a la valoración. Al no existir un spot de GPU-hora directamente almacenable y negociable con las propiedades requeridas por una replicación estándar, no se presupone una medida neutral al riesgo única identificada mediante argumentos convencionales de *carry*. La dinámica bajo $\mathbb{Q}$ se interpreta, por tanto, como una *ley de valoración modelizada* dentro del experimento cuantitativo, no como una medida recuperada de una superficie líquida de derivados sobre compute. La distinción entre dinámica física y de valoración se formaliza en el Capítulo 4.

Desde el punto de vista económico, la ausencia de un mercado completo no elimina el riesgo de precio para un consumidor recurrente de capacidad. Si la exposición depende del coste soportado a lo largo de varios periodos, resulta natural representarla mediante un derivado ligado al precio medio, lo que conduce a las opciones asiáticas.

2.2. Valoración de opciones asiáticas

Las opciones asiáticas son derivados *path-dependent*: su payoff depende de una media de precios observados durante un periodo, no sólo del precio terminal Sánchez Sánchez, 2026. El presente trabajo se limita a una call europea de strike fijo, media aritmética y fixings discretos. Si $0 < t_1 < \dots < t_N = T$, la media terminal y el payoff son

$$\bar{P}_T = \frac{1}{N} \sum_{i=1}^N P_{t_i}, \quad H_T = (\bar{P}_T - K)^+. \quad (2.1)$$

La dependencia de trayectoria implica que, una vez iniciado el periodo de *averaging*, el estado contractual debe conservar la información ya fijada en la media. Por tanto, la valoración no puede reducirse únicamente al spot y al tiempo hasta vencimiento; también debe incorporar la contribución acumulada de los fixings realizados. La representación concreta de ese estado se define en el Capítulo 4.

La elección de la media aritmética introduce la principal dificultad numérica. Bajo el entorno lognormal clásico, la media geométrica es analíticamente más tratable y permite una valoración analítica útil como control de varianza Kemna y Vorst, 1990. Turnbull y Wakeman proponen una aproximación para la media aritmética Turnbull y Wakeman, 1991. La media aritmética, en cambio, es una suma de variables lognormales correlacionadas y no dispone de una distribución cerrada simple. De ahí la utilización histórica de métodos aproximados y numéricos: Monte Carlo con reducción de varianza Kemna y Vorst, 1990, aproximaciones analíticas Turnbull y Wakeman, 1991, condicionamiento sobre la media geométrica Curran, 1994 y técnicas de reducción dimensional y cotas Rogers y Shi, 1995.

En este TFM no se comparan dichas aproximaciones. La media aritmética se mantiene porque representa directamente el riesgo económico que se desea modelizar. Para un usuario que compra capacidad de forma recurrente, el coste medio durante el horizonte está relacionado con el promedio de los precios pagados. Una call sobre ese promedio puede interpretarse, de forma estilizada, como protección frente a que el coste medio supere un umbral K . El contrato es hipotético: no se presupone la existencia actual de un mercado líquido de opciones asiáticas sobre GPU-hora.

La combinación de media aritmética, fixings discretos y estado contractual acumulado convierte la valoración en un problema adecuado para simulación y para el estudio de *surrogate models*. El objetivo no es sólo aproximar el precio, sino también su sensibilidad respecto al precio actual de compute.

2.3. Modelos de commodities y reversión a la media

El movimiento browniano geométrico (GBM) constituye el benchmark clásico en valoración de opciones por su positividad, transición exacta y simplicidad Black y Scholes, 1973; Merton, 1973; Sánchez Sánchez, 2026. Sin embargo, no incorpora un nivel de largo plazo ha-

cia el que el precio tienda a retornar. En determinados mercados de commodities, factores de oferta, demanda, capacidad productiva y sustitución motivan modelos con reversión a la media. La literatura documenta esta característica en distintos mercados y la incorpora explícitamente en modelos de commodities y electricidad Bessembinder et al., 1995; Cartea y Figueroa, 2005; Gibson y Schwartz, 1990; Lucia y Schwartz, 2002; Schwartz, 1997.

Una representación parsimoniosa es el proceso de Ornstein–Uhlenbeck (OU) Uhlenbeck y Ornstein, 1930. Para evitar precios negativos, el presente trabajo aplica la reversión al logaritmo del precio, $X_t = \log P_t$:

$$dX_t = \kappa(\theta - X_t) dt + \sigma dW_t, \quad P_t = e^{X_t} > 0, \quad \kappa > 0. \quad (2.2)$$

La desviación respecto a θ decae como $e^{-\kappa u}$ y la vida media de un shock es $\log(2)/\kappa$. Además, la transición del OU es exacta y su varianza condicional converge a $\sigma^2/(2\kappa)$. Estas propiedades hacen del Log-OU un entorno especialmente conveniente para generar trayectorias sin introducir error de discretización entre fechas de simulación. En régimen estacionario, $\exp(\theta)$ corresponde a la mediana del precio, mientras que la media es $\exp\{\theta + \sigma^2/(4\kappa)\}$.

La elección de un modelo de un factor responde a parsimonia, no a una afirmación de verdad estructural. La literatura propone modelos más ricos con *convenience yield*, tipos de interés estocásticos, estacionalidad o saltos Cartea y Figueroa, 2005; Gibson y Schwartz, 1990; Lucia y Schwartz, 2002; Schwartz, 1997. Sin embargo, la historia disponible del benchmark H100 es corta y no existe una curva líquida de derivados sobre compute que permita identificar de forma robusta factores adicionales. El Log-OU se utiliza, por tanto, como modelo principal parsimonioso, mientras que el GBM mantiene su papel de benchmark conceptual.

Tabla 2.1. Comparación conceptual entre GBM y Log-OU

Propiedad	GBM	Log-OU
Positividad del precio	Sí	Sí, mediante $P_t = e^{X_t}$
Reversión a la media	No	Sí
Nivel de largo plazo	No explícito	θ en log-precios
Persistencia de shocks	Sin fuerza de retorno	Decae como $e^{-\kappa u}$
Varianza de largo plazo	Crece con el horizonte	Converge en log-precios

Debe distinguirse, finalmente, entre la dinámica física $(\kappa_P, \theta_P, \sigma_P)$ estimada sobre datos históricos y los parámetros de valoración $(\kappa_Q, \theta_Q, \sigma_Q)$. En commodities líquidos, la estructura de futuros puede aportar información sobre estas dinámicas y las primas de riesgo Gibson y Schwartz, 1990; Schwartz, 1997. En compute no se dispone de una estructura equivalente suficientemente líquida; por ello, $\mathbb{Q}$ vuelve a interpretarse como una ley de valoración modelizada. Esta separación condiciona el alcance de las conclusiones y evita identificar indebidamente parámetros históricos con parámetros neutrales al riesgo.

2.4. Monte Carlo y Randomized Quasi-Monte Carlo

Monte Carlo es una herramienta estándar para valorar derivados cuando la esperanza del payoff no admite una solución analítica, y resulta especialmente natural en contratos dependientes de trayectoria Boyle, 1977; Glasserman, 2004; Sánchez Sánchez, 2026. Para un estado $\mathbf{x}$, el precio puede escribirse como

$$V(\mathbf{x}) = \mathbb{E}^Q[G(\mathbf{Z}; \mathbf{x})], \quad (2.3)$$

donde G es el payoff descontado y $\mathbf{Z}$ contiene las innovaciones que generan la trayectoria futura. El estimador Monte Carlo convencional converge con error de orden $M^{-1/2}$, lo que puede exigir un número elevado de simulaciones cuando se necesitan etiquetas precisas para muchos estados Glasserman, 2004.

Quasi-Monte Carlo (QMC) sustituye números pseudoaleatorios independientes por secuencias de baja discrepancia diseñadas para cubrir de forma más uniforme el hipercubo de integración Caflisch, 1998; Sobol', 1967. La aleatorización de esas secuencias da lugar a Randomized Quasi-Monte Carlo (RQMC), que conserva la estructura de baja discrepancia y permite utilizar replicaciones aleatorizadas para estimar el error numérico Owen, 1997. En problemas de valoración, esta combinación puede mejorar la eficiencia de integración respecto a Monte Carlo convencional, aunque la ganancia depende de la dimensión y regularidad efectiva del integrando Caflisch, 1998; Glasserman, 2004.

El interés de RQMC en este TFM es instrumental. El motor de simulación genera para cada estado una etiqueta de precio y una Delta de referencia. La sensibilidad puede estimarse mediante diferencias finitas o mediante un estimador *pathwise*. Las diferencias finitas son conceptualmente simples, pero requieren revalorar el contrato bajo perturbaciones del input y su precisión depende del tamaño del *bump*. Cuando el payoff permite intercambiar diferenciación y esperanza, el método *pathwise* estima directamente la derivada de cada trayectoria Broadie y Glasserman, 1996; Glasserman, 2004. En el trabajo, las diferencias finitas se utilizan como control numérico de las etiquetas *pathwise*, no como generador principal.

Esta separación es importante para interpretar el experimento: MLP y DML no aprenden un “precio verdadero” de mercado, sino la función inducida por el Log-OU y aproximada mediante RQMC. La precisión de las etiquetas limita la información disponible para el aprendizaje. Por ello se distingue entre conjuntos ordinarios de entrenamiento/evaluación y un conjunto de referencia generado con mayor presupuesto RQMC, utilizado para verificar que las conclusiones no dependan del ruido numérico de las etiquetas.

2.5. Machine Learning para pricing

Un motor de valoración por simulación puede ser preciso pero costoso cuando debe evaluarse repetidamente sobre un gran número de estados. Las redes neuronales permiten trasladar parte de ese coste a una fase *offline*: se generan etiquetas con el motor numérico y posteriormente

se entrena una función $\widehat{V}_\theta(\mathbf{x})$ que actúa como *surrogate*. Este enfoque no sustituye la definición financiera del precio; aproxima la función producida por el modelo de valoración.

La utilización de redes neuronales en derivados tiene antecedentes tempranos. Hutchinson et al. (1994) emplean *learning networks* para aproximar funciones de pricing y estudiar cobertura fuera de muestra. Trabajos posteriores han extendido el enfoque a valoración, volatilidad implícita y calibración Horvath et al., 2021; Liu et al., 2019; Ruf y Wang, 2020. El atractivo del surrogate reside en combinar flexibilidad no lineal y evaluaciones rápidas una vez concluido el entrenamiento.

En este TFM, el benchmark es un *Multi-Layer Perceptron* entrenado de forma supervisada con etiquetas de precio. Dado un conjunto $\{(\mathbf{x}_i, V_i)\}_{i=1}^N$, el objetivo convencional penaliza el error entre V_i y $\widehat{V}_\theta(\mathbf{x}_i)$. Como la red es diferenciable, puede obtenerse posteriormente una Delta mediante diferenciación automática:

$$\widehat{\Delta}_{\text{MLP}} = \frac{\partial \widehat{V}_\theta}{\partial P}. \quad (2.4)$$

No obstante, una buena aproximación de los niveles no garantiza una aproximación igualmente buena de las pendientes. La pérdida de precio no contiene una restricción explícita sobre la forma local de la superficie. Este punto es especialmente relevante en derivados, donde las Greeks son variables de gestión del riesgo y no simples productos secundarios de la función de pricing. Por ello, el MLP convencional proporciona un benchmark natural para evaluar el valor incremental de utilizar información diferencial durante el entrenamiento.

2.6. Differential Machine Learning

Differential Machine Learning (DML) amplía el aprendizaje supervisado incorporando, junto a cada etiqueta de valor, información sobre sus derivadas respecto a los inputs. Huge y Savine (Huge & Savine, 2020) proponen esta formulación para problemas financieros en los que el motor de simulación puede producir sensibilidades conjuntamente con los valores.

En el caso del presente trabajo, la diferencia frente al MLP es deliberadamente acotada. Ambos modelos aproximan la misma función de valoración, utilizan los mismos estados y comparten la misma familia arquitectónica; DML añade supervisión sobre la Delta. De forma esquemática,

$$\text{MLP: } (\mathbf{x}, V), \quad \text{DML: } (\mathbf{x}, V, \Delta). \quad (2.5)$$

La función objetivo combina un término de precio y otro diferencial. En forma genérica,

$$\mathcal{L}_{\text{DML}} = \mathcal{L}_V + \lambda_\Delta \mathcal{L}_\Delta, \quad \mathcal{L}_\Delta \propto \left\| \frac{\partial \widehat{V}_\theta}{\partial P} - \Delta \right\|^2, \quad (2.6)$$

con el escalado y la ponderación definidos posteriormente en la metodología. La su-

pervisión diferencial restringe así no sólo el nivel de la superficie aprendida, sino también su pendiente local. No equivale a una regularización convencional: no se penaliza que la derivada sea grande, sino que se aleje de una etiqueta diferencial de referencia Hugué y Savine, 2020.

La principal motivación es la eficiencia informativa. Si el motor RQMC proporciona precio y Delta para un mismo estado, cada ejemplo contiene información sobre el nivel y la geometría local de la función. Hugué y Savine (Hugué & Savine, 2020) muestran que esta estructura puede mejorar la aproximación de sensibilidades y la eficiencia muestral. En este TFM, sin embargo, “eficiencia muestral” se utiliza de forma estrictamente empírica: se comprobará si DML alcanza una precisión determinada con menos estados dentro de la malla experimental, sin atribuir una equivalencia universal entre una derivada y un número fijo de observaciones adicionales.

DML introduce también costes y riesgos. La calidad del entrenamiento depende de la calidad de las etiquetas diferenciales; un error sistemático en la Delta puede convertirse en supervisión incorrecta. Además, precio y derivada deben escalarse de forma coherente, la pérdida requiere diferenciación de orden superior respecto a los parámetros de la red y el coste de entrenamiento aumenta frente al MLP convencional. Finalmente, como cualquier surrogate, su validez está condicionada al dominio cubierto por los datos y no garantiza extrapolación fiable Hugué y Savine, 2020.

La comparación MLP–DML se diseña precisamente para aislar esta diferencia de información. El interés empírico no termina en comprobar si disminuye el error de Delta: dado que la sensibilidad se utiliza después para cobertura, debe evaluarse si la mejora estadística tiene una traducción económica.

2.7. Cobertura y evaluación económica

La Delta mide la respuesta local del valor del derivado al factor de riesgo, $\Delta_t = \partial V_t / \partial P_t$. En el marco clásico de Black–Scholes–Merton, una posición adecuada en el propio subyacente permite neutralizar localmente esa exposición y constituye la base de la replicación Black y Scholes, 1973; Merton, 1973. Sin embargo, la cobertura real introduce fricciones que separan la precisión de la Greek del resultado económico de la estrategia.

La primera es el rebalanceo discreto. Incluso utilizando la Delta correcta del modelo, la posición permanece fija entre dos fechas mientras la sensibilidad de la opción cambia. La literatura clásica muestra que esta discretización genera error de cobertura Boyle y Emanuel, 1980; con costes de transacción, aumentar la frecuencia de ajuste introduce además un compromiso entre error de replicación y coste de negociación Leland, 1985. Por ello, una Delta exacta no implica una replicación dinámica exacta en tiempo discreto.

La segunda dificultad aparece cuando el factor de riesgo no es directamente negociable. La literatura de hedging con futuros y *cross-hedging* estudia precisamente posiciones en instrumentos relacionados y el riesgo residual derivado de una relación imperfecta con la exposición

original Anderson y Danthine, 1981; Ederington, 1979. Esta situación es relevante para compute: la Delta respecto al precio de GPU-hora sigue siendo una medida de sensibilidad, pero no implica que puedan negociarse directamente Δ_t unidades de un spot almacenable.

El diseño empírico separa por ello dos preguntas. La cobertura local comprueba si una Delta estimada reproduce mejor la respuesta del derivado ante una pequeña perturbación del precio. La cobertura dinámica transforma esa sensibilidad en una posición sobre un forward de compute modelizado y permite que contrato, factor e instrumento evolucionen entre rebalanceos. Si $J_t^G = \partial G_t / \partial P_t$ es la sensibilidad del valor actual del instrumento de cobertura, la neutralidad local requiere

$$h_t = \frac{\Delta_t}{J_t^G}, \quad \widehat{h}_t - h_t^* = \frac{\widehat{\Delta}_t - \Delta_t^*}{J_t^G}. \quad (2.7)$$

Esta expresión muestra por qué el error de Delta puede amplificarse cuando $|J_t^G|$ es pequeño. Bajo una dinámica con fuerte reversión a la media, un cambio del spot actual puede tener un efecto atenuado sobre un precio forward de una fecha posterior, de modo que la conversión desde Delta a unidades de hedge puede ser sensible. El mecanismo no implica que toda observación extrema se explique por el Jacobiano, pero justifica analizar por separado el error de la Greek y el error terminal de la estrategia.

La evaluación económica debe considerar, por tanto, la distribución completa del error de cobertura. RMSE, MAE y mediana absoluta capturan aspectos distintos y deben complementarse con percentiles de cola y comparaciones trayectoria a trayectoria. Esta distinción resulta especialmente importante cuando unas pocas trayectorias concentran una fracción elevada del error cuadrático.

2.8. Posicionamiento y aportación del TFM

La literatura revisada sitúa el trabajo en la intersección de tres líneas. La primera estudia la capacidad informática como recurso perecedero y sus mecanismos de pricing Li et al., 2016; Wu et al., 2019; Xu y Li, 2013; la segunda desarrolla métodos de valoración y cobertura mediante redes neuronales, culminando en la incorporación explícita de información diferencial Huge y Savine, 2020; Hutchinson et al., 1994; la tercera analiza la relación entre Greeks, rebalanceo y efectividad de cobertura Anderson y Danthine, 1981; Boyle y Emanuel, 1980; Ederington, 1979.

El TFM conecta estas líneas mediante una comparación emparejada de MLP y DML sobre una asiática de compute: evalúa si aprender mejor la Delta se traduce en menor riesgo local y dinámico. La aportación reside en contrastar esa transmisión dentro de un mismo modelo de valoración y distinguir sus límites contractuales.

3. Datos y mercado de capacidad de cómputo

3.1. Capacidad de cómputo como activo económico

El desarrollo y despliegue de sistemas de inteligencia artificial requiere infraestructura especializada, energía y redes, y la expansión reciente de esta capacidad ha aumentado la relevancia económica del cómputo (International Energy Agency, 2025; Stanford Institute for Human-Centered Artificial Intelligence, 2026). Para el análisis financiero conviene distinguir entre la GPU física, que es un bien de capital, y el servicio temporal que genera. En este trabajo el subyacente es este segundo concepto:

$$P_t = \text{precio de alquiler de capacidad de cómputo en el instante } t, \quad (3.1)$$

expresado según la fuente en unidades monetarias por GPU-hora. Una GPU-hora es un servicio perecedero: la capacidad no utilizada en una hora no puede almacenarse para consumirla posteriormente. Esta propiedad limita la aplicación directa de los argumentos clásicos de almacenamiento y *cash-and-carry* (Bandi & Su, 2026). Por ello, el TFM trata el precio de acceso a compute como una exposición económica no almacenable y no presupone la existencia de un mercado completo de derivados sobre GPU-hora, aunque este tipo de contratos haya comenzado a recibir atención regulatoria y de mercado (Commodity Futures Trading Commission, 2026).

3.2. Mercado de alquiler de GPU

El precio de una GPU no es homogéneo entre proveedores ni modalidades. En los mercados de infraestructura *cloud* coexisten contratación *on-demand*, capacidad *spot* o interrumpible y compromisos de utilización de mayor duración, con diferencias en precio, disponibilidad y flexibilidad (Amazon Web Services, s.f.-a, s.f.-b; Google Cloud, s.f.-a, s.f.-b). La literatura sobre *cloud* muestra que estas condiciones contractuales forman parte del problema económico de adquisición de capacidad (Lin et al., 2022).

En consecuencia, una referencia de precio debe interpretarse condicionada por, al menos, el modelo de GPU, la región y la modalidad contractual. Esta heterogeneidad determina el tratamiento empírico del capítulo: la serie Ornn H100 se utiliza como referencia principal para caracterización y calibración, mientras que las series SMM H100 aportan evidencia complementaria del mercado chino. No se interpreta la diferencia entre ambas fuentes como un *spread* arbitrable.

3.3. Ornn Compute Price Index

La fuente principal es el *Ornn Compute Price Index* (OCPI), una familia de índices por modelo de GPU expresados en USD por GPU-hora. Su metodología utiliza alquileres ejecutados

de capacidad *on-demand*, excluyendo cotizaciones indicativas, capacidad reservada y contratos de largo plazo (Ornn Data LLC, 2026c). Para cada modelo, el índice se construye como una media winsorizada ponderada por número de GPU:

$$I_{g,t} = \frac{\sum_{i \in \mathcal{M}_{g,t}} n_i \tilde{p}_i}{\sum_{i \in \mathcal{M}_{g,t}} n_i}, \quad (3.2)$$

donde $\tilde{p}_i$ es el precio ejecutado tras la winsorización. La estructura general es pública, pero los proveedores permanecen anonimizados y el percentil exacto de winsorización no se divulga, por lo que el investigador externo no puede reconstruir cada valor histórico desde sus componentes (Ornn Data LLC, 2026c).

El estudio utiliza el *daily reference print* de NVIDIA H100 SXM accesible mediante la API de Ornn (Ornn, 2026; Ornn Data LLC, 2026a). La muestra congelada contiene **92 observaciones diarias entre el 26 de mayo y el 25 de agosto de 2026**, en USD por GPU-hora. Esta serie es la única referencia de mercado empleada para caracterizar la dinámica física y calibrar el Log-OU principal. La copia local se conserva para reproducibilidad porque la ventana histórica accesible puede variar con el tiempo. La extracción H100 se realizó el 26 de agosto de 2026; el panel multi-GPU se extrajo el 27 de agosto de 2026, según los metadatos conservados.

3.4. SMM y el mercado chino de capacidad de cómputo

Como referencia del mercado chino se utiliza información de Shanghai Metals Market (SMM). En 2026 SMM amplió su cobertura al alquiler de capacidad GPU y anunció dos familias de datos: un índice de precios y una serie de *listing prices*, publicadas oficialmente desde el 3 de julio de 2026 (Shanghai Metals Market, 2026a). La primera combina información de mercado para construir una referencia estandarizada; la segunda refleja precios públicos de oferta y no se interpreta como equivalente a una transacción ejecutada.

Las referencias SMM incorporan explícitamente dimensiones contractuales:

$$\mathcal{S} = \{\text{modelo, VRAM, tipo de instancia, región, modalidad contractual}\}. \quad (3.3)$$

Para el análisis principal se selecciona *SMM-H100-80G-Multi-GPU Node-WR-Monthly Reserved* (SMM-GPU-CC-019), correspondiente a un nodo H100-80G en la región occidental de China con contratación mensual. Como contraste regional se utiliza la referencia equivalente para el delta del río Yangtsé (SMM-GPU-CC-005), cuya especificación de referencia contempla un servidor dedicado con 8× NVIDIA H100-80G (Shanghai Metals Market, 2026b, 2026c).

Ornn y SMM no representan contratos fungibles: Ornn mide capacidad *on-demand* por GPU-hora, mientras que la referencia china principal es mensual y regional. La conversión a una unidad horaria no elimina las diferencias de duración, disponibilidad, localización o configuración. Por ello SMM se utiliza sólo como evidencia descriptiva complementaria y no interviene

en la calibración del modelo principal.

3.5. Selección del H100 como subyacente principal

El estudio se centra en NVIDIA H100 como caso cuantitativo. La elección combina relevancia tecnológica y, sobre todo, observabilidad: H100 aparece tanto en el benchmark global de Ornn como en las referencias regionales de SMM (NVIDIA Corporation, s.f.; Ornn Data LLC, 2026b; Shanghai Metals Market, 2026c). Mantener constante la arquitectura reduce una fuente de heterogeneidad al comparar ambos mercados, aunque no elimina las diferencias contractuales.

La serie H100 SXM de Ornn queda fijada *ex ante* como subyacente principal. Las referencias H200, B200, A100 SXM4 y RTX 5090 disponibles en Ornn se reservan para contraste descriptivo y no se utilizan para seleccionar retrospectivamente el modelo o recalibrar el experimento (Ornn Data LLC, 2026b).




Figura 3.1. Evolución de los precios de alquiler por GPU en Ornn durante la muestra analizada. Panel extraído el 27/08/2026.

La selección debe interpretarse como un estudio de caso y no como un índice representativo de todo el mercado de compute. Otras generaciones de GPU pueden presentar niveles, liquidez y dinámicas temporales diferentes y requerirían una recalibración específica.

3.6. Tratamiento de las series y construcción de variables

Los datos originales se conservan sin modificación y las transformaciones se realizan sobre copias derivadas. La muestra principal de Ornn queda congelada en las 92 observaciones indicadas anteriormente. Para SMM se conserva igualmente una extracción fija de las referencias Western Region y Yangtze River Delta. Dado que la familia SMM fue lanzada después del inicio de algunas observaciones históricas incluidas en la extracción, esos registros se interpretan como historia facilitada por la fuente y no como evidencia de publicación en tiempo real anterior al

lanzamiento.

La limpieza convierte fechas y precios a tipos válidos, excluye registros sin fecha o precio utilizable y ordena cronológicamente cada serie. En los diagnósticos de una misma serie se conserva la última observación si una fecha aparece repetida. La muestra principal Ornn H100 contiene 92 precios positivos, sin fechas duplicadas, valores ausentes en fecha o precio ni huecos diarios entre sus extremos. Los campos opcionales no utilizados pueden estar vacíos. No se aplica un recorte adicional de valores extremos a los índices preservados: la winsorización de Ornn pertenece a la construcción del índice por su proveedor. En SMM se mantienen las fechas disponibles, sin interpolar ni rellenar días sin publicación; las comparaciones utilizan únicamente fechas comunes. Al tratarse de índices de alquiler, no proceden ajustes por dividendos o splits de acciones, y se conserva separada cada referencia contractual.

Para estudiar cambios relativos se emplea el log-retorno

$$r_t = \ln \left(\frac{P_t}{P_{t-1}} \right), \quad (3.4)$$

mientras que para la calibración Log-OU se trabaja con el log-precio

$$X_t = \ln P_t. \quad (3.5)$$

Las comparaciones entre fuentes se restringen a fechas comunes,

$$\mathcal{T}_{ij} = \mathcal{T}_i \cap \mathcal{T}_j, \quad (3.6)$$

y, para evitar interpretar diferencias de moneda, nivel y contrato como diferencias directamente comparables, cada serie se normaliza a Base 100:

$$B_t = 100 \frac{P_t}{P_{t_0}}. \quad (3.7)$$

Las correlaciones se utilizan únicamente como medidas descriptivas de co-movimiento y no como evidencia causal o de integración de mercados:

$$\rho_{ij} = \frac{\text{Cov}(r_{i,t}, r_{j,t})}{\sigma_i \sigma_j}. \quad (3.8)$$

3.7. Comparación descriptiva entre el mercado global y chino

La Figura 3.2 compara las referencias H100 global y chinas tras normalizarlas a Base 100. El objetivo es estudiar su evolución relativa, no construir un precio común ni un diferencial negociable.

Durante la ventana disponible, Western Region aumenta aproximadamente un 4,39 % y Yangtze River Delta un 9,63 %. En las 42 fechas comunes de la comparación principal, la correlación en niveles Base 100 es aproximadamente 0,777 para Ornn–Western Region y 0,704




Figura 3.2. Evolución normalizada del precio H100: Ornn y SMM. Muestras congeladas el 26/08/2026.

para Ornn–Yangtze River Delta:

$$\rho(B^{\text{Ornn}}, B^{\text{West}}) \approx 0,777, \quad (3.9)$$

$$\rho(B^{\text{Ornn}}, B^{\text{YRD}}) \approx 0,704. \quad (3.10)$$

Sin embargo, el co-movimiento desaparece al analizar variaciones de corto plazo: la correlación de log-retornos es aproximadamente $-0,136$ con Western Region y $0,036$ con Yangtze River Delta. Estos resultados aconsejan no interpretar la elevada correlación de niveles normalizados como evidencia de integración de mercados o de una relación de equilibrio.

$$\rho(r^{\text{Ornn}}, r^{\text{West}}) \approx -0,136, \quad (3.11)$$

$$\rho(r^{\text{Ornn}}, r^{\text{YRD}}) \approx 0,036. \quad (3.12)$$

3.8. Limitaciones de los datos

La principal limitación es la longitud de la muestra. Las 92 observaciones de Ornn permiten una caracterización exploratoria y una especificación parsimoniosa, pero no identifican con precisión propiedades estructurales de largo plazo. La historia SMM es todavía más corta. Esta restricción motiva el uso posterior de un Log-OU de un factor y el análisis de incertidumbre mediante bootstrap.

La segunda limitación es contractual. Ornn y SMM difieren en modalidad, localización y construcción del benchmark; normalizar las series no elimina estas diferencias. Por ello la comparación global–China es exclusivamente descriptiva.

La tercera es de transparencia. Ornn publica la metodología general del OCPI, pero no la

composición detallada de proveedores ni todos los parámetros necesarios para reconstruir el índice. SMM, por su parte, combina distintas fuentes de información de mercado. En ambos casos se conservan localmente las muestras utilizadas y los benchmarks se tratan como observaciones externas.

Finalmente, H100 no representa todo el mercado de compute y las referencias regionales seleccionadas tampoco representan todo el mercado chino. La heterogeneidad observada entre arquitecturas y regiones impide extrapolar automáticamente los resultados a otras GPU.

4. Metodología

4.1. Definición del contrato asiático

El instrumento estudiado es una call asiática europea de precio medio, cuyo payoff depende de la media aritmética de N precios observados en un calendario de fixings $0 < t_1 < \dots < t_N = T$ (Kemna & Vorst, 1990; Turnbull & Wakeman, 1991):

$$\bar{P}_T = \frac{1}{N} \sum_{i=1}^N P_{t_i}, \quad H_T = (\bar{P}_T - K)^+. \quad (4.1)$$

En una fecha intermedia $t < T$, sea $m(t)$ el número de fixings ya observados. Se define su contribución al promedio terminal como

$$C_t = \frac{1}{N} \sum_{i=1}^{m(t)} P_{t_i}, \quad \bar{P}_T = C_t + \frac{1}{N} \sum_{i=m(t)+1}^N P_{t_i}. \quad (4.2)$$

Así, el spot actual no basta para valorar el contrato: el estado debe recoger también la parte del promedio ya fijada. En los experimentos se utiliza un vencimiento máximo de un año, $N = 12$ fixings y strike normalizado $K = 1$. Se denota $\tau = T - t$ y las variables monetarias se expresan respecto a K .

Esta estructura es coherente con la motivación económica del trabajo: si un usuario adquiere capacidad de cómputo de forma recurrente, su exposición puede estar más relacionada con el coste medio soportado durante el periodo que con un único precio terminal. Todos los experimentos utilizan nocional unitario; los resultados pueden escalarse linealmente a otras cantidades contractuales bajo los supuestos del modelo.

4.2. Problema de valoración y medida de valoración

Para un tipo de interés determinista r , el valor modelizado se define como

$$V_t^{\mathbb{Q}} = e^{-r\tau} \mathbb{E}^{\mathbb{Q}} [(\bar{P}_T - K)^+ \mid \mathcal{F}_t]. \quad (4.3)$$

La notación $\mathbb{Q}$ distingue la dinámica empleada para valorar de la dinámica física $\mathbb{P}$, siguiendo la separación habitual entre probabilidades históricas y de valoración (Sánchez Sánchez, 2026). Sin embargo, la interpretación requiere cautela. La capacidad de cómputo es un servicio no almacenable y el precio spot utilizado no corresponde a un activo que pueda comprarse y almacenarse mediante una estrategia estándar de *cash-and-carry*. Por ello, no se identifica empíricamente una medida martingala equivalente única a partir de un mercado completo de derivados. Esta limitación es análoga a la que aparece en otros mercados de bienes no almacenables (Bandi &

Su, 2026; Bessembinder & Lemmon, 2002).

Bajo $\mathbb{P}$ se estima una dinámica Log-OU a partir de la serie H100,

$$dX_t = \kappa_P(\theta_P - X_t)dt + \sigma_P dW_t^{\mathbb{P}}, \quad (4.4)$$

mientras que para valoración se utiliza una ley de la misma familia,

$$dX_t = \kappa_Q(\theta_Q - X_t)dt + \sigma_Q dW_t^{\mathbb{Q}}. \quad (4.5)$$

Los parámetros $(\kappa_Q, \theta_Q, \sigma_Q)$ deben interpretarse, por tanto, como parámetros de una *ley de valoración modelizada*. El escenario central Q_0 adopta la calibración física como referencia,

$$Q_0 : \quad \kappa_Q = \widehat{\kappa}_P, \quad \theta_Q = \widehat{\theta}_P, \quad \sigma_Q = \widehat{\sigma}_P, \quad (4.6)$$

igualando por construcción las leyes física y de valoración del índice en el escenario central, sin introducir una prima de riesgo en esa parametrización. Esta elección no constituye evidencia de ausencia de prima de riesgo en el mercado real. El experimento amplía posteriormente estos parámetros dentro de bandas de diseño para evitar que los surrogates aprendan exclusivamente una calibración puntual. En consecuencia, los precios obtenidos son precios de modelo condicionados a la especificación de $\mathbb{Q}$, no cotizaciones observadas de opciones H100.

4.3. Geometric Brownian Motion como benchmark

El movimiento browniano geométrico (GBM) sirve como benchmark clásico (Black & Scholes, 1973; Merton, 1973; Sánchez Sánchez, 2026). Su dinámica convencional de valoración es

$$dP_t = rP_t dt + \sigma P_t dW_t^{\mathbb{Q}}, \quad (4.7)$$

cuya transición exacta es

$$P_{t+u} = P_t \exp \left[\left(r - \frac{1}{2}\sigma^2 \right) u + \sigma \sqrt{u} Z \right], \quad Z \sim \mathcal{N}(0, 1). \quad (4.8)$$

La opción aritmética se valora por simulación, pues su payoff depende de varios fixings y no dispone en general de una solución cerrada tan simple como la del caso europeo estándar (Glaserman, 2004; Kemna & Vorst, 1990). El GBM se utiliza únicamente como benchmark clásico sin reversión a la media; la evidencia H100 y el objetivo económico del TFM motivan que el Log-OU sea la especificación principal.

4.4. Modelo Log-OU y reversión a la media

El modelo principal sigue una estructura de Ornstein–Uhlenbeck para el log-precio, inspirada en el modelo de un factor de Schwartz (1997). Sea $Y_t = \log P_t$. Bajo la medida física,

$$dY_t = \kappa_P(\vartheta_P - Y_t)dt + \sigma_P dW_t^{\mathbb{P}}. \quad (4.9)$$

Para trabajar en unidades relativas al strike se define $X_t = \log(P_t/K)$ y $\theta_P = \vartheta_P - \log K$. La normalización no altera κ_P ni σ_P .

Para parámetros genéricos (κ, θ, σ) , la transición exacta en un intervalo Δ es

$$X_{t+\Delta} = \theta + e^{-\kappa\Delta}(X_t - \theta) + \sigma\sqrt{\frac{1 - e^{-2\kappa\Delta}}{2\kappa}} Z, \quad Z \sim \mathcal{N}(0, 1). \quad (4.10)$$

Por tanto,

$$\mathbb{E}[X_{t+u} | X_t] = \theta + e^{-\kappa u}(X_t - \theta), \quad \text{Var}(X_{t+u} | X_t) = \frac{\sigma^2}{2\kappa}(1 - e^{-2\kappa u}). \quad (4.11)$$

La desviación respecto al nivel de largo plazo decae exponencialmente y la vida media es $t_{1/2} = \log(2)/\kappa$. Para $\kappa > 0$, la distribución estacionaria del log-precio es normal con varianza $\sigma^2/(2\kappa)$. El modelo garantiza precios positivos, permite simulación exacta y mantiene una parametrización parsimoniosa, ventajas importantes dada la longitud limitada de la serie H100. No obstante, impone parámetros constantes, gaussianidad y un único factor, por lo que no incorpora saltos, volatilidad estocástica, estacionalidad ni cambios de régimen.

La simulación bajo $\mathbb{Q}$ utiliza la misma transición exacta sustituyendo los parámetros físicos por $(\kappa_Q, \theta_Q, \sigma_Q)$ y recupera el precio como $P_{t+\Delta} = K \exp(X_{t+\Delta})$. Esta formulación permite estudiar una familia controlada de escenarios de valoración sin presentar sus parámetros como una calibración neutral al riesgo observada en mercado.

4.5. Calibración física y construcción del dominio paramétrico

La dinámica física se estima mediante la representación AR(1) implícita en la transición exacta del OU. Para observaciones equiespaciadas,

$$Y_t = a + \phi Y_{t-\Delta} + \varepsilon_t, \quad \phi = e^{-\kappa_P \Delta}, \quad a = \vartheta_P(1 - \phi). \quad (4.12)$$

De aquí se obtienen

$$\widehat{\kappa}_P = -\frac{\log \widehat{\phi}}{\Delta}, \quad \widehat{\vartheta}_P = \frac{\widehat{a}}{1 - \widehat{\phi}}, \quad \widehat{\sigma}_P = \widehat{\sigma}_\varepsilon \sqrt{\frac{2\widehat{\kappa}_P}{1 - \widehat{\phi}^2}}. \quad (4.13)$$

Se adopta $\Delta = 1/365$, por lo que κ_P y σ_P quedan expresados en escala anual.

Dada la corta historia disponible, la incertidumbre de calibración se analiza mediante un bootstrap residual del AR(1) con 20 000 réplicas (Efron & Tibshirani, 1993). En cada réplica se remuestran los residuos centrados, se reconstruye recursivamente una serie y se reestiman los parámetros; se conservan únicamente realizaciones con $0 < \hat{\phi}^* < 1$. El bootstrap se utiliza para estudiar la sensibilidad de la calibración y para definir el dominio del surrogate, no como una identificación de parámetros neutrales al riesgo.

Las bandas principales de diseño para la velocidad de reversión y la volatilidad corresponden aproximadamente a los percentiles P10–P90 del bootstrap,

$$\kappa_Q \in [25, 87], \quad \sigma_Q \in [0,55, 0,71]. \quad (4.14)$$

El nivel de largo plazo se trata separadamente para no confundir incertidumbre física con ajuste bajo $\mathbb{Q}$. Con $K_{\text{ref}} = \exp(\hat{\vartheta}_P)$ y el estado normalizado respecto a ese nivel, se fija el rango

$$\theta_Q \in [-0,1641, 0,1610], \quad (4.15)$$

con $\theta_Q = 0$ en el escenario central. Estas bandas son dominio de diseño, no intervalos de confianza de una medida neutral al riesgo.

Como diagnóstico adicional, la capacidad predictiva a un paso del AR(1) se compara fuera de muestra con un paseo aleatorio. Esta comparación no pretende probar que el Log-OU sea la ley verdadera del mercado, sino comprobar si la reversión a la media aporta información frente a un benchmark persistente.

4.6. Randomized Quasi-Monte Carlo

La valoración requiere integrar sobre los fixings futuros de una opción path-dependent. Para un estado $\mathbf{x}$ y d fixings pendientes,

$$V(\mathbf{x}) = \mathbb{E}^{\mathbb{Q}}[g(\mathbf{Z}; \mathbf{x})] = \int_{[0,1]^d} g(\Phi^{-1}(\mathbf{u}); \mathbf{x}) d\mathbf{u}. \quad (4.16)$$

El Monte Carlo convencional se sustituye por redes Sobol aleatorizadas mediante *scrambling*, es decir, Randomized Quasi-Monte Carlo (RQMC) (Owen, 1997; Sobol', 1967). La aleatorización conserva la cobertura de baja discrepancia y permite disponer de réplicas independientes para medir la variabilidad del estimador. No se impone una tasa asintótica específica para el payoff asiático; la elección de RQMC se apoya en su comportamiento numérico y en su capacidad para generar etiquetas precisas a coste controlado.

Para cada punto Sobol se transforman sus coordenadas a normales estándar y se propagan secuencialmente mediante la transición exacta Log-OU. Si los d fixings futuros son $t_{j_1}, \dots, t_{j_d}$,

$$\bar{P}_T^{(n)} = C_t + \frac{1}{N} \sum_{\ell=1}^d P_{t_{j_\ell}}^{(n)}, \quad \widehat{V}_{RQMC} = e^{-r\tau} \frac{1}{M} \sum_{n=1}^M (\bar{P}_T^{(n)} - K)^+. \quad (4.17)$$

La transición exacta evita error de discretización Euler; el error numérico procede esencialmente de la integración.

Cada estado utiliza una aleatorización propia. Los conjuntos de entrenamiento, validación y test emplean $M = 8192 = 2^{13}$ puntos y una aleatorización por estado. El conjunto de referencia emplea 16 aleatorizaciones independientes de 8192 puntos, de modo que cada etiqueta de referencia agrega 131 072 evaluaciones de trayectoria. Conviene distinguir este RQMC de un segundo uso de Sobol: el diseño de escenarios sintéticos descrito más adelante. El primero integra una esperanza condicional; el segundo cubre el espacio de estados.

4.7. Estimación pathwise de Delta

La sensibilidad principal es

$$\Delta_t = \frac{\partial V_t}{\partial P_t}, \quad (4.18)$$

manteniendo fija la contribución histórica C_t . Bajo el Log-OU, condicionada una realización de las innovaciones,

$$\frac{\partial P_{t+u}}{\partial P_t} = e^{-\kappa_Q u} \frac{P_{t+u}}{P_t}. \quad (4.19)$$

Como los fixings pasados no cambian ante una perturbación del spot actual, $\partial C_t / \partial P_t = 0$ y

$$\frac{\partial \bar{P}_T}{\partial P_t} = \frac{1}{N} \sum_{i=m(t)+1}^N e^{-\kappa_Q(t_i-t)} \frac{P_{t_i}}{P_t}. \quad (4.20)$$

Por tanto, casi seguramente,

$$\Delta_t = e^{-r\tau} \mathbb{E}^Q \left[\mathbf{1}_{\{\bar{P}_T > K\}} \frac{1}{N} \sum_{i=m(t)+1}^N e^{-\kappa_Q(t_i-t)} \frac{P_{t_i}}{P_t} \middle| \mathcal{F}_t \right]. \quad (4.21)$$

La misma trayectoria RQMC proporciona así el precio y su derivada, sin revaloraciones adicionales. Esta propiedad es especialmente útil para DML. Además, al normalizar $s = P_t/K$ y $v = V_t/K$ se mantiene $\partial v / \partial s = \Delta_t$.

La implementación pathwise se valida mediante diferencias finitas centrales con *common random numbers*,

$$\Delta_t^{FD}(h) = \frac{V(P_t + h, C_t, \dots) - V(P_t - h, C_t, \dots)}{2h}, \quad (4.22)$$

utilizadas exclusivamente como diagnóstico. La Delta debe interpretarse como sensibilidad del modelo; no implica por sí misma que el spot de cómputo sea un instrumento directamente negociable y replicante.

4.8. Construcción del conjunto de datos sintético

No existe una base observable de opciones asiáticas líquidas sobre H100 que proporcione simultáneamente precios y Greeks. La serie real se utiliza para caracterizar la dinámica física y definir regiones plausibles; las etiquetas de precio y Delta se generan mediante RQMC bajo las leyes de valoración del experimento. Por tanto, los targets son datos sintéticos de modelo.

Con $K = 1$, se define $s_t = P_t/K$ y

$$c_t = \frac{C_t}{K} = \frac{1}{N} \sum_{i=1}^{m(t)} \frac{P_{t_i}}{K}. \quad (4.23)$$

Si a_t es la media de los fixings ya realizados, entonces $c_t = (m(t)/N)a_t$. El vector final de inputs es

$$\mathbf{x} = (s_t, c_t, \tau, r, \kappa_Q, \theta_Q, \sigma_Q) \in \mathbb{R}^7. \quad (4.24)$$

Los parámetros de $\mathbb{Q}$ se incluyen para que un único surrogate aprenda una familia de funciones de valoración.

Tabla 4.1. Dominio del experimento sintético Log-OU.

Variable	Rango	Papel
P_0/K	[0,85, 1,175]	condición inicial física
τ	[0,05, 1,00]	vencimiento restante
r	[0,00, 0,08]	descuento
κ_Q	[25, 87]	reversión bajo $\mathbb{Q}$
θ_Q	[-0,1641, 0,1610]	nivel Log-OU bajo $\mathbb{Q}$
σ_Q	[0,55, 0,71]	volatilidad bajo $\mathbb{Q}$
P_t/K	[0,70, 1,30]	filtro del estado realizado
a_t	[0,70, 1,30]	filtro de media pasada

Un diseño Sobol aleatorizado cubre inicialmente las seis variables exógenas

$$(P_0/K, \tau, r, \kappa_Q, \theta_Q, \sigma_Q).$$

Una vez fijado $t = T - \tau$, se genera bajo $\mathbb{P}$ una única historia Log-OU hasta t y de ella se obtienen conjuntamente P_t/K y c_t . Ambos estados no se muestrean de forma independiente. Los candidatos se aceptan cuando el spot realizado y, si existen fixings previos, su media se encuentran dentro del dominio de la Tabla 4.1. Después, condicionado ese estado, los fixings

futuros y las etiquetas (V, Δ) se generan bajo $\mathbb{Q}$. El esquema es, por tanto,

$$\begin{aligned} \text{diseño paramétrico} &\rightarrow \text{historia bajo } \mathbb{P} \rightarrow (P_t, C_t) \\ &\rightarrow \text{valoración bajo } \mathbb{Q}. \end{aligned} \quad (4.25)$$

Los tamaños congelados del diseño experimental son 65 536 estados de entrenamiento, 8 192 de validación, 8 192 de test y 1 024 de referencia. Para estudiar eficiencia muestral, el training se organiza en subconjuntos anidados

$$\mathcal{D}_{1024} \subset \mathcal{D}_{4096} \subset \mathcal{D}_{16384} \subset \mathcal{D}_{65536}. \quad (4.26)$$

Los cuatro conjuntos principales se generan independientemente desde el origen, con semillas diferentes para el estado físico y para la valoración RQMC.

El número de fixings futuros y la distancia al siguiente fixing se conservan como metadatos, pero no se incorporan al vector de siete inputs. Esta decisión se mantuvo congelada antes del test. Con el calendario fijo, τ determina el número de fixings pendientes y sus distancias temporales; con la convención posterior al fixing, $m(t) = \lfloor 12t \rfloor$ para $0 \leq t < 1$, salvo tolerancias numéricas. Incluir esos metadatos podría facilitar la aproximación de los cambios de régimen, aunque no añadiría información al estado. En cada fixing, C_t incluye ya el precio observado.

4.9. MLP supervisado únicamente por precios

El benchmark neuronal es una MLP que aprende el precio normalizado $v = V/K$ únicamente a partir de las etiquetas de valor. Las redes feedforward son aproximadores flexibles de funciones multivariantes (Hornik et al., 1989); su calidad se determina aquí de forma empírica sobre muestras no utilizadas para el ajuste.

Inputs y precio se estandarizan con medias y desviaciones calculadas exclusivamente sobre cada subconjunto de entrenamiento,

$$\tilde{x}_j = \frac{x_j - \mu_{x_j}}{\sigma_{x_j}}, \quad \tilde{v} = \frac{v - \mu_v}{\sigma_v}. \quad (4.27)$$

La arquitectura compartida por MLP y DML es residual, con anchura 128, activación SiLU y tres bloques residuales de dos transformaciones lineales, siguiendo la idea general de aprendizaje residual (He et al., 2016). Con siete inputs contiene 100 225 parámetros entrenables. La salida es lineal y aproxima el precio estandarizado.

El MLP minimiza únicamente

$$\mathcal{L}_{MLP} = \frac{1}{n} \sum_{i=1}^n (f_{\omega}(\tilde{\mathbf{x}}_i) - \tilde{v}_i)^2, \quad (4.28)$$

por lo que la Delta no interviene en el entrenamiento. La optimización sigue la Tabla 4.2. Se

ejecutan 3000 épocas sin *early stopping* y se conserva el checkpoint con menor MSE de precio estandarizado en validación.

Aunque no recibe supervisión diferencial, la red es diferenciable. Mediante autodiferenciación (Baydin et al., 2018), su Delta implícita es

$$\widehat{\Delta}^{MLP} = \frac{\sigma_v}{\sigma_s} \frac{\partial f_\omega}{\partial \widetilde{s}}, \quad (4.29)$$

donde $s = P_t/K$. Así puede compararse la calidad de una derivada aprendida de forma implícita con la obtenida cuando esa derivada forma parte explícita de la supervisión.

4.10. Differential Machine Learning

DML amplía la regresión por valores incorporando información sobre derivadas de la función objetivo, siguiendo el enfoque de Huge y Savine (2020). Para aislar el efecto de esta información, DML utiliza exactamente la misma arquitectura, inicialización, optimizador y procedimiento de checkpoint que el MLP. La única diferencia sistemática es la función de pérdida.

La Delta debe transformarse de forma coherente con la estandarización. Si $\widetilde{s} = (s - \mu_s)/\sigma_s$ y $\widetilde{v} = (v - \mu_v)/\sigma_v$, la etiqueta diferencial en coordenadas estandarizadas es

$$\widetilde{\Delta} = \frac{\partial \widetilde{v}}{\partial \widetilde{s}} = \Delta \frac{\sigma_s}{\sigma_v}. \quad (4.30)$$

Para evitar que su escala domine mecánicamente la función objetivo se aplica una normalización RMS calculada únicamente sobre training,

$$w_\Delta = \left[\frac{1}{n} \sum_{i=1}^n \widetilde{\Delta}_i^2 \right]^{-1/2}. \quad (4.31)$$

La pérdida combina precio y derivada,

$$\mathcal{L}_{DML} = \alpha \mathcal{L}_V + \beta \mathcal{L}_\Delta, \quad \alpha = \frac{1}{1 + \lambda_\Delta}, \quad \beta = \frac{\lambda_\Delta}{1 + \lambda_\Delta}, \quad (4.32)$$

donde $\mathcal{L}_V$ es el MSE del precio estandarizado y $\mathcal{L}_\Delta$ el MSE de la derivada estandarizada y ponderada por w_Δ . La derivada de la salida neuronal respecto al spot se obtiene por autodiferenciación dentro del propio grafo de entrenamiento, por lo que el backpropagation de $\mathcal{L}_\Delta$ requiere derivadas de orden superior respecto a los parámetros de la red.

En el protocolo final, el peso seleccionado antes del test es $\lambda_\Delta = 0,25$, equivalente a $\alpha = 0,8$ y $\beta = 0,2$. DML no recibe supervisión sobre otras Greeks ni modifica la arquitectura para acomodar la información adicional. Por tanto, la comparación evalúa de forma directa si añadir la Delta a cada observación mejora la aproximación del precio y, especialmente, de su gradiente.

4.11. Selección de hiperparámetros y protocolo de congelación

Para evitar que la comparación MLP–DML quede condicionada por una búsqueda arquitectónica específica del problema de *compute*, la arquitectura y el optimizador se heredan del benchmark GBM previamente confirmado y congelado. En ese benchmark, la selección se realizó sobre un MLP entrenado sólo con precios mediante una regla de un error estándar sobre el MSE de precio medio multi-seed; entre los candidatos admisibles se priorizaron después menor número de parámetros y menor tiempo de entrenamiento. La Tabla 4.2 recoge la configuración transferida al problema Log-OU. No se reoptimizan arquitectura ni optimizador tras introducir los dos parámetros adicionales del estado Log-OU; con los siete inputs finales la red contiene 100 225 parámetros entrenables.

Tabla 4.2. Configuración neuronal compartida por MLP y DML.

Hiperparámetro	Configuración final
Backbone	Residual
Anchura / bloques	128 / 3
Activación	SiLU
Optimizador / scheduler	AdamW / coseno
Learning rate inicial	$1,9616 \times 10^{-3}$
Weight decay	$6,6341 \times 10^{-7}$
Batch size	1024
Máximo de épocas	3000
Checkpoint	MSE de precio estandarizado

Para el problema de *compute* sólo se vuelve a seleccionar el peso diferencial. Se evalúa $\lambda_\Delta \in \{0,25, 0,5, 1, 2, 4\}$ con 8192 observaciones y las semillas $\{1701, 3701, 5701\}$, con un máximo de 1500 épocas. Tras una permutación determinista, el conjunto de validación destinado a esta etapa se divide en dos mitades disjuntas: la primera selecciona el epoch exclusivamente mediante MSE de precio estandarizado; la segunda compara los valores de λ_Δ y nunca interviene en la selección del checkpoint. El criterio de comparación es

$$\mathcal{S}_\lambda = \frac{1}{2} \text{MSE}_{V,\text{std}} + \frac{1}{2} \text{MSE}_{\Delta,\text{std,RMS}}, \quad (4.33)$$

y se minimiza su media entre semillas. El valor seleccionado es $\lambda_\Delta = 0,25$. El valor 4,0 pertenece al benchmark previo y no se utiliza como peso diferencial del experimento final de *compute*.

La secuencia experimental puede resumirse como

$$\begin{aligned} \text{benchmark GBM congelado} &\rightarrow \text{transferencia al estado Log-OU} \\ &\rightarrow \text{selección de } \lambda_\Delta \rightarrow \text{freeze} \rightarrow \text{evaluación final.} \end{aligned} \quad (4.34)$$

Antes de evaluar test y referencia quedan fijados los siete inputs, arquitectura, peso diferencial, normalización, batch size, criterio de checkpoint, tamaños y semillas. Los diagnósticos posterior-

res sólo se utilizan para interpretar errores y limitaciones; no permiten reentrenar ni modificar el protocolo.

La evaluación final emplea cuatro tamaños de entrenamiento: 1 024, 4 096, 16 384 y 65 536 observaciones. Para cada tamaño se utilizan cinco semillas: 1701, 2701, 3701, 4701 y 5701. Para cada pareja tamaño–semilla se entrenan un MLP y un DML con la misma arquitectura y protocolo, generando 40 ejecuciones. Las muestras de entrenamiento son anidadas, de modo que la curva de aprendizaje compara cantidades crecientes de información manteniendo la estructura experimental. Las cinco semillas varían el entrenamiento sobre los mismos estados de evaluación; su dispersión no mide incertidumbre por regeneración del dataset. Los veinte pares tamaño–semilla tampoco constituyen veinte réplicas independientes del diseño de datos.

4.12. Validación numérica, consistencia y control de leakage

La validación se estructura alrededor de cuatro riesgos: coherencia de los estados, corrección de las etiquetas, consistencia computacional y aislamiento del test. Primero se comprueba que cada escenario satisface la identidad contractual $n_{past} + n_{future} = N$, que C_t coincide con la contribución de los fixings ya observados, que los parámetros y estados están dentro del dominio y que no existen valores no finitos.

Train, validación, test y referencia se generan con identificadores y semillas separados para la historia física y para el RQMC. Se comprueba la ausencia de solapamientos entre escenarios y aleatorizaciones. El scaler de inputs y precio, así como el factor RMS diferencial, se ajustan exclusivamente sobre el training de cada ejecución; las demás muestras se transforman con esos parámetros ya fijados.

Los controles conservados abarcan 12 estados para diferencias finitas centrales con *common random numbers* y otros 12 para la comparación CPU/Torch. La discrepancia pathwise/FD media es $1,8811 \times 10^{-7}$ y la máxima $1,3414 \times 10^{-6}$; los máximos CPU/Torch son $5,5511 \times 10^{-17}$ en precio y $6,9389 \times 10^{-18}$ en Delta. Son controles puntuales satisfactorios, no una cota uniforme del error de las etiquetas. El dataset final y el Oracle dinámico usan float32; la coincidencia a precisión máquina del control conservado no certifica todo ese recorrido. La prima inicial dinámica agrega ocho aleatorizaciones de 8192 puntos en float64 y el Oracle dinámico usa 4096 puntos por estado y una aleatorización.

Los metadatos finales registran PyTorch 2.12.1+cu126 y CUDA 12.6. El material reproducible distingue estas versiones verificadas de las dependencias compatibles y conserva la procedencia de los scripts recuperados para diagnósticos intermedios.

Finalmente, el protocolo queda congelado antes del test y cada ejecución se vincula a su configuración. MLP y DML se comparan de manera emparejada, con la misma arquitectura, mismos estados, misma inicialización y mismo orden de minibatches; la diferencia deliberada es la supervisión de Delta. Los listados completos de semillas, hashes y comprobaciones operativas se reservan para el material reproducible, ya que no alteran la lógica estadística del experimento.

4.13. Diseños de cobertura y evaluación económica

La precisión de una Greek no garantiza por sí sola una mejora económica. Por ello se plantean dos ejercicios complementarios: una cobertura local, que aísla la calidad de la sensibilidad, y un stress test dinámico con un forward de cómputo modelizado, que incorpora la conversión de Delta en una decisión de cobertura.

Cobertura local

Para un estado $(P_t, C_t, \dots)$ se aplica un pequeño shock $\Delta P = P_t \varepsilon$ manteniendo fija la parte histórica del contrato. El cambio real de valor se estima con RQMC y se compara con la aproximación de primer orden $\widehat{\Delta}_t \Delta P$. El residuo cubierto es

$$R^m = \Delta V - \widehat{\Delta}_t^m \Delta P, \quad m \in \{MLP, DML, oracle\}, \quad (4.35)$$

y el benchmark sin cobertura es $R^0 = \Delta V$. El shock principal es del 1 %, con robustez al 0,5 % y 2 %, en ambas direcciones. Se evalúan RMSE, MAE y comparaciones emparejadas. Este ejercicio mide directamente la capacidad de la Delta para neutralizar pequeñas variaciones del valor, sin convertirla todavía en una estrategia dinámica. Se emplean 6140 estados procedentes de cuatro bloques de 128 trayectorias, con dos direcciones por shock: 12 280 comparaciones dependientes. Los estados se toman en el punto medio de los primeros once intervalos y en un punto interior del último, a unos 15,21 y 8,52 días de la frontera más próxima, respectivamente. La prueba dinámica evalúa, en cambio, estados posteriores a cada fixing.

Cobertura dinámica con forward modelizado

El spot de capacidad no se considera directamente negociable en la forma necesaria para una réplica clásica. Se introduce, por tanto, un forward conceptual que liquida en el siguiente fixing. Bajo el escenario Q_0 , si $h_j = t_{j+1} - t_j$, la transición Log-OU implica

$$F_j = \mathbb{E}^{Q_0}[P_{t_{j+1}} | \mathcal{F}_{t_j}] = \exp \left[\theta_Q + a_j (X_{t_j} - \theta_Q) + \frac{1}{2} v_j^2 \right], \quad a_j = e^{-\kappa_Q h_j}, \quad (4.36)$$

donde $v_j^2 = \sigma_Q^2 (1 - e^{-2\kappa_Q h_j}) / (2\kappa_Q)$. Su sensibilidad al spot es

$$J_j = \frac{\partial F_j}{\partial P_{t_j}} = e^{-\kappa_Q h_j} \frac{F_j}{P_{t_j}}, \quad (4.37)$$

y la política efectivamente ejecutada para una opción vendida fue

$$q_j = \frac{\widehat{\Delta}_{t_j}}{J_j}. \quad (4.38)$$

Esta política histórica omite el descuento de la sensibilidad del contrato. Para un forward con precio de entrega fijado L , el valor actual y la posición que neutraliza exactamente la Delta del valor de la opción son

$$G_t = e^{-r(u-t)} [F(t, u) - L], \quad q_t^{\text{PV}} = e^{r(u-t)} \frac{\widehat{\Delta}_t}{J_t}. \quad (4.39)$$

Se distingue el precio de entrega F del valor del contrato G : coste inicial nulo no permite omitir el descuento. Las tablas principales conservan la política congelada $q_j = \widehat{\Delta}/J_j$; la Sección 5.7 cuantifica por separado la corrección posterior, sin reentrenamiento. La división por J_j es esencial: con reversión rápida, la sensibilidad del forward al spot puede ser reducida y amplificar el impacto de un error de Delta sobre el nocional de cobertura.

La estrategia se rebalancea después de cada fixing. Las trayectorias económicas se generan bajo $\mathbb{P}$, mientras que precio, Deltas y forward se calculan bajo Q_0 . El forward contratado en t_j produce en t_{j+1} $q_j(P_{t_{j+1}} - F_j)$. Desde la perspectiva del vendedor de la opción, el error terminal de una estrategia m es

$$E_T^m = V_0 e^{rT} + \sum_{j=0}^{N-1} q_j^m (P_{t_{j+1}} - F_j) e^{r(T-t_{j+1})} - H_T, \quad (4.40)$$

y sin cobertura $E_T^0 = V_0 e^{rT} - H_T$.

El stress test central utiliza $P_0/K = 1$, $r = 3\%$, parámetros de Q_0 y cuatro bloques independientes de 512 trayectorias físicas. Sólo se conservan trayectorias cuyos estados de rebalanceo permanecen dentro del dominio común de los modelos: 2038 de 2048, el 99,51 %. El filtro utiliza la permanencia en todos los rebalanceos y es común a las estrategias; no selecciona por sus errores. Las métricas son condicionales a esa permanencia, no el riesgo incondicional bajo $\mathbb{P}$. Las decisiones de cobertura usan información contemporánea. No se aplica clipping a Deltas ni a nocionales. MLP y DML utilizan el promedio de los cinco modelos finales entrenados con $n = 65\,536$, mientras que el oracle recalcula la Delta por RQMC.

La evaluación dinámica utiliza RMSE y MAE del error terminal, percentiles de $|E_T|$, concentración del error cuadrático en las colas y comparaciones emparejadas frente a MLP y no hedge. Además, se diagnostica el error por número de fixings pendientes y proximidad a la siguiente fecha contractual, ya que esas variables discretas no forman parte explícita del estado neuronal.

La prueba local evalúa $dV \simeq \Delta dP$ en estados interiores y la dinámica evalúa la política forward en fronteras, ausentes exactamente del entrenamiento sintético. Cambian simultáneamente calendario, instrumento y acumulación de errores; su comparación no aísla causalmente cada mecanismo.

5. Resultados

5.1. Evidencia de reversión a la media y calibración del Log-OU

La primera etapa evalúa si la dinámica observada del precio H100 es compatible con el Log-OU utilizado posteriormente para construir el entorno sintético de valoración. El objetivo no es identificar un modelo “verdadero” del mercado de cómputo, sino comprobar si una especificación parsimoniosa con reversión a la media resulta defendible con la evidencia disponible y cuantificar la incertidumbre de calibración.

Sobre las 92 observaciones diarias de Ornn, la estimación $Y_{t+1} = a + \phi Y_t + \varepsilon_{t+1}$, con $Y_t = \log P_t$, proporciona $\hat{a} = 0,08498$, $\hat{\phi} = 0,91440$ y $R^2 = 0,8145$. El intervalo convencional al 95 % de ϕ , $[0,8225, 1,0063]$, contiene la unidad. Asimismo, el ADF no rechaza raíz unitaria ($p = 0,356$), mientras que el KPSS tampoco rechaza estacionariedad ($p \geq 0,10$). En consecuencia, el valor puntual es compatible con reversión a la media, pero la corta muestra no permite establecer de forma concluyente la estacionariedad del nivel logarítmico.

$$\hat{\phi} = 0,91440, \quad (5.1)$$

$$IC_{95\%}(\phi) = [0,8225, 1,0063]. \quad (5.2)$$

La transformación exacta de AR(1) a Log-OU conduce a los parámetros de la Tabla 5.1. La velocidad de reversión estimada implica una vida media de 7,75 días, lo que constituye una reversión económicamente rápida dentro de la especificación.

$$\hat{\kappa}_P = 32,6645, \quad (5.3)$$

$$\hat{\vartheta}_P = 0,99269, \quad \exp(\hat{\vartheta}_P) = 2,6985, \quad (5.4)$$

$$\hat{\sigma}_P = 0,6247, \quad (5.5)$$

$$t_{1/2} = 7,75 \text{ días}. \quad (5.6)$$

Como contraste predictivo, una evaluación *expanding one-step* del log-precio produce un RMSE de 0,03161 para AR(1), frente a 0,03209 para un random walk, y un MAE de 0,02384 frente a 0,02466. Las mejoras, 1,50 % y 3,34 %, respectivamente, son positivas pero moderadas. Los contrastes HAC de diferencia de pérdidas dan $p = 0,145$ para pérdida cuadrática y $p = 0,0627$ para absoluta; no establecen superioridad al 5 %. Esta evidencia justifica utilizar Log-OU como modelo principal parsimonioso, no descartar dinámicas alternativas.

La incertidumbre paramétrica se cuantifica mediante 20 000 réplicas bootstrap residuales, de las que se conservan 19 994 estacionarias y se descartan seis. La Tabla 5.2 muestra que la dispersión es especialmente elevada en κ . El rango P10–P90 se utiliza para informar, y no identificar, el dominio sintético de valoración.

Tabla 5.1. Calibración física del modelo Log-OU sobre Ornn H100.

Magnitud	Estimación
Observaciones	92
Intercepto AR(1), $\widehat{a}$	0,08498
Persistencia, $\widehat{\phi}$	0,91440
$IC_{95\%}$ de ϕ	[0,8225, 1,0063]
R^2 AR(1)	0,8145
$\widehat{\kappa}_P$ anual	32,6645
$\widehat{\vartheta}_P$	0,99269
$\exp(\widehat{\vartheta}_P)$	2,6985
$\widehat{\sigma}_P$ anual	0,6247
Vida media	7,75 días

Tabla 5.2. Sensibilidad bootstrap de los parámetros Log-OU.

Rango central	κ	σ	Vida media (días)
P10–P90	[25,055, 87,047]	[0,5508, 0,7119]	[2,91, 10,10]
P5–P95	[20,523, 102,382]	[0,5279, 0,7357]	[2,47, 12,33]
P2.5–P97.5	[17,240, 117,480]	[0,5100, 0,7542]	[2,15, 14,67]

De acuerdo con el protocolo del Capítulo 4, los rangos de diseño se fijan como

$$\kappa_Q \in [25, 87], \quad \sigma_Q \in [0,55, 0,71], \quad (5.7)$$

mientras que el nivel de largo plazo se normaliza alrededor de $K_{\text{ref}} = 2,6985$ y los extremos observados de Ornn determinan

$$\theta_Q \in [-0,1641, 0,1610]. \quad (5.8)$$

Estos intervalos son *bandas de diseño* para explorar riesgo de modelo; no son intervalos de confianza de parámetros neutrales al riesgo. La evidencia histórica bajo $\mathbb{P}$ informa la elección del dominio, pero no identifica por sí sola la dinámica bajo la medida de valoración modelizada $\mathbb{Q}$.

5.2. Resultados de valoración: MLP frente a DML

La comparación principal utiliza pares MLP–DML entrenados con las mismas muestras, semillas e hiperparámetros congelados; la diferencia sistemática es la supervisión diferencial de DML. La Tabla 5.3 recoge el error del precio normalizado en test para los cuatro tamaños de entrenamiento.

Con 1 024 y 4 096 estados las diferencias son reducidas. Con 16 384, DML presenta menor error medio, pero elevada dispersión entre semillas y sólo obtiene menor RMSE en uno de los cinco pares, por lo que no se interpreta como una mejora sistemática. La configuración

Tabla 5.3. Error de valoración en el conjunto de test

N_{train}	RMSE MLP	RMSE DML	MAE MLP	MAE DML
1 024	$0,009217 \pm 0,000034$	$0,009232 \pm 0,000045$	$0,005961 \pm 0,000071$	$0,005911 \pm 0,000114$
4 096	$0,008747 \pm 0,000009$	$0,008767 \pm 0,000039$	$0,005330 \pm 0,000041$	$0,005326 \pm 0,000079$
16 384	$0,008438 \pm 0,000013$	$0,007610 \pm 0,001995$	$0,005002 \pm 0,000022$	$0,004316 \pm 0,001636$
65 536	$0,001624 \pm 0,000043$	$0,001516 \pm 0,000130$	$0,000123 \pm 0,000025$	$0,000136 \pm 0,000046$

Nota: media $\pm$ desviación muestral entre cinco semillas sobre los mismos estados.

final de 65 536 estados es más estable: DML reduce el RMSE de 0,001624 a 0,001516 (aproximadamente 6,7 %) y gana cuatro de cinco comparaciones emparejadas. En cambio, el MLP obtiene menor MAE: $1,226 \times 10^{-4}$ frente a $1,356 \times 10^{-4}$, de modo que el MAE de DML es aproximadamente un 10,6 % mayor que el de MLP; MLP gana tres de cinco pares. Por tanto,

$$\text{RMSE}_{DML} < \text{RMSE}_{MLP}, \quad \text{MAE}_{DML} > \text{MAE}_{MLP}. \quad (5.9)$$

La diferencia entre MAE y RMSE anticipa una distribución del error distinta, analizada en la Sección 5.4.

El conjunto de referencia, construido con dieciséis aleatorizaciones RQMC por estado, favorece más claramente a DML en la configuración final: el RMSE pasa de 0,001163 (MLP) a 0,000801 (DML), una media de reducciones emparejadas de aproximadamente el 30,4 % y cinco de cinco pares favorables. El MAE es 0,000128 frente a 0,000116, aunque DML sólo gana tres de cinco pares. En conjunto, DML mantiene una precisión de pricing comparable y mejora algunas métricas, especialmente el RMSE final y de referencia, pero **no domina uniformemente la valoración**.

5.3. Precisión de Delta y eficiencia muestral

La diferencia entre modelos es mucho más clara en Delta. La Tabla 5.4 muestra que DML obtiene menor MAE y RMSE que MLP en las cinco semillas para los cuatro tamaños de entrenamiento.

Tabla 5.4. Error de Delta en el conjunto de test

N_{train}	MAE MLP	MAE DML	RMSE MLP	RMSE DML	DML mejor
1 024	$0,020884 \pm 0,001163$	$0,010468 \pm 0,002188$	$0,029881 \pm 0,001880$	$0,014870 \pm 0,002114$	5/5
4 096	$0,018047 \pm 0,001601$	$0,006254 \pm 0,000112$	$0,026927 \pm 0,003220$	$0,011204 \pm 0,000132$	5/5
16 384	$0,013890 \pm 0,000487$	$0,005232 \pm 0,001798$	$0,020542 \pm 0,000552$	$0,009674 \pm 0,002136$	5/5
65 536	$0,001234 \pm 0,000264$	$0,000216 \pm 0,000085$	$0,008528 \pm 0,001257$	$0,001817 \pm 0,000245$	5/5

Nota: media $\pm$ desviación muestral entre cinco semillas sobre los mismos estados.

En la configuración de 65 536 estados, DML reduce el MAE de 0,001234 a 0,000216 y el RMSE de 0,008528 a 0,001817. Las reducciones emparejadas medias son, respectivamente, 82,0 % y 78,5 %. El R^2 de Delta pasa de 0,7603 para MLP a 0,9891 para DML. La mejora se reproduce en el conjunto de referencia: MAE de 0,001404 frente a 0,000198 y RMSE de 0,009372 frente a 0,001158, con cinco de cinco pares favorables.




Figura 5.1. RMSE de Delta en test según el tamaño del conjunto de entrenamiento.

Las curvas de aprendizaje aportan además evidencia de mayor eficiencia muestral. DML con 1 024 estados alcanza MAE 0,010468 y RMSE 0,014870, ambos inferiores a los 0,013890 y 0,020542 del MLP entrenado con 16 384 estados. Este resultado demuestra que, *dentro de la malla experimental*, DML puede alcanzar mayor precisión de Delta con sustancialmente menos estados; no implica una tasa universal de eficiencia de 16 veces. La misma ordenación se reproduce en referencia.

Esta eficiencia muestral tampoco equivale a menor coste de entrenamiento. En la configuración final, los tiempos medios son aproximadamente 2 494 s para MLP y 3 363 s para DML, de modo que la supervisión diferencial incrementa el tiempo cerca de un 35 %. La ventaja consiste en extraer más información útil de cada estado de entrenamiento, especialmente sobre la sensibilidad de la función de valoración.

5.4. Errores extremos de precio y Delta

Los percentiles superiores permiten determinar si las diferencias de error proceden del comportamiento general o de una fracción reducida de estados. La Tabla 5.5 resume P95, P99 y máximo para la configuración final.

Tabla 5.5. Colas del error absoluto de precio y Delta en test, $N_{\text{train}} = 65\,536$

Magnitud	Modelo	P95	P99	Máximo
Precio	MLP	$2,367 \times 10^{-4}$	$6,176 \times 10^{-4}$	$8,389 \times 10^{-2}$
Precio	DML	$2,723 \times 10^{-4}$	$5,031 \times 10^{-4}$	$7,677 \times 10^{-2}$
Delta	MLP	$3,262 \times 10^{-3}$	$9,424 \times 10^{-3}$	0,5115
Delta	DML	$4,880 \times 10^{-4}$	$1,229 \times 10^{-3}$	0,0790

Nota: medias de los P95, P99 y máximos de cada ejecución; no son estadísticos globales ni del ensemble.

En precio, MLP obtiene menor P95, mientras que DML reduce P99 aproximadamente 18,5 % y el máximo de 0,08389 a 0.07677. Esto es coherente con el menor MAE del MLP y

el menor RMSE de DML: el modelo diferencial no mejora toda la distribución, pero contiene mejor parte de la cola extrema. El patrón cualitativo se mantiene en el conjunto de referencia, donde DML también presenta menor P99 y máximo.

En Delta la ventaja es mucho más intensa: DML reduce P95 aproximadamente 85 %, P99 87 % y el máximo 84,6 %. En referencia se obtiene una conclusión similar, con máximos de 0,2486 para MLP y 0,0337 para DML. Por tanto, la supervisión diferencial mejora no sólo el error medio de Delta, sino también las regiones más adversas del dominio evaluado. Los estadísticos de cola no identifican, sin embargo, qué características de los estados originan esos episodios; esta cuestión motiva el diagnóstico contractual siguiente.

Un diagnóstico posterior de las predicciones finales identifica violaciones de positividad y monotonidad: la salida lineal no impone $V \geq 0$ ni $\Delta \geq 0$. Sobre 8192 estados de test y cinco semillas (40 960 predicciones por modelo), los precios negativos representan el 14,73 % en MLP y el 13,05 % en DML; los mínimos son $-0,004049$ y $-0,000885$. Las Deltas negativas representan el 20,06 % y el 14,17 %, con mínimos $-0,241302$ y $-0,013681$. La frecuencia incluye valores próximos a cero; el material reproducible conserva también conteos por debajo de -10^{-6} . No se recortan las predicciones ni se modifican las métricas principales. La mejora de DML no garantiza restricciones financieras globales.

5.5. Efecto de las fronteras de fixing

La opción contiene 12 fixings mensuales. El vector de entrada incorpora el tiempo a vencimiento, pero no codifica explícitamente ni la distancia a la frontera de fixing más próxima ni el número de fixings pendientes. Estas variables se conservaron como metadatos, lo que permite realizar un diagnóstico *post-hoc* sobre los modelos ya congelados, sin utilizar el test para rediseñar o reentrenar.

Definiendo d_{fix} como la distancia, en días, a la frontera mensual más próxima, la mediana del diagnóstico de test es 7,54 días; entre los 50 mayores errores de Delta de DML cae a 0,49 días. La Tabla 5.6 muestra una concentración muy superior a la frecuencia de estas regiones en la muestra.

Tabla 5.6. Concentración de los 50 mayores errores de Delta de DML alrededor de fronteras de fixing

Distancia	Muestra total	Top 50 DML	Sobrerrepresentación
$\leq 0,5$ días	3,30 %	52 %	15,8×
≤ 1 día	6,65 %	64 %	9,6×
≤ 2 días	13,27 %	88 %	6,6×
≤ 3 días	19,91 %	92 %	4,6×

El patrón aparece también al agrupar el error medio por distancia. A menos de medio día de una frontera, el MAE de Delta es 0,005153 para MLP y 0,001742 para DML; a más de tres días cae a 0,000832 y 0,000128, respectivamente.

La correlación de Spearman entre $|\varepsilon_{DML}^{\Delta}|$ y d_{fix} en todo el diagnóstico es sólo $-0,161$.

Tabla 5.7. Error absoluto medio de Delta según distancia a una frontera de fixing

Distancia	n	MLP	DML
$\leq 0,5$ días	270	0,005153	0,001742
$(0,5, 1]$ días	275	0,003835	0,000506
$(1, 3]$ días	1 086	0,002034	0,000295
> 3 días	6 561	0,000832	0,000128




Figura 5.2. Error absoluto medio de Delta según la distancia a la frontera de fixing más próxima.

Por tanto, la proximidad a un fixing no explica globalmente el error de Delta; su efecto aparece sobre todo en la cola. DML mantiene además menor error que MLP en todos los intervalos, por lo que el problema parece asociado a la representación del régimen contractual más que a una pérdida de la ventaja relativa de DML.

El patrón se mantiene cualitativamente en referencia, aunque con menor concentración. La interpretación es que, con el calendario fijo, τ determina toda la información temporal de los fixings. Una codificación explícita de $n_{\text{fix}}^{\text{future}}$ y d_{fix} podría facilitar la representación de los cambios discretos de régimen sin añadir información. Esta modificación no se implementa por haber sido identificada después de congelar el protocolo y queda como extensión futura.

5.6. Cobertura local: transmisión económica de la mejora en Delta

La cobertura local estudia si la mayor precisión de Delta se traduce en una menor exposición de primer orden ante perturbaciones pequeñas. Para un shock ΔP se evalúa

$$\varepsilon_{\text{hedge}} = \Delta V - \widehat{\Delta}_t \Delta P, \quad (5.10)$$

frente al residuo sin cobertura ΔV . Se comparan no-hedge, MLP, DML y una Delta Oracle RQMC. El shock principal es 1 %, con 0,5 % y 2 % como robustez.

Con el shock del 1 %, DML reduce el RMSE aproximadamente 84,2 % frente al MLP y 99,2 % frente a no cubrir. El MAE confirma la misma jerarquía: $1,2003 \times 10^{-4}$ (no-hedge),

Tabla 5.8. RMSE de cobertura local según magnitud del shock

Shock	Sin cobertura	MLP	DML	Oracle RQMC
0,5 %	$6,7744 \times 10^{-5}$	$3,3379 \times 10^{-6}$	$5,0278 \times 10^{-7}$	$8,9543 \times 10^{-8}$
1,0 %	$1,3549 \times 10^{-4}$	$6,6878 \times 10^{-6}$	$1,0584 \times 10^{-6}$	$3,4914 \times 10^{-7}$
2,0 %	$2,7096 \times 10^{-4}$	$1,3428 \times 10^{-5}$	$2,4162 \times 10^{-6}$	$1,3738 \times 10^{-6}$

$4,4943 \times 10^{-6}$ (MLP), $8,2692 \times 10^{-7}$ (DML) y $2,6240 \times 10^{-7}$ (Oracle), lo que supone una mejora de DML del 81,6 % respecto al MLP. En 12 280 comparaciones emparejadas del shock principal, DML supera al MLP en 86,1 % y al no-hedge en 97,5 %. La ordenación del RMSE se mantiene para los tres tamaños de shock y en los cuatro bloques físicos independientes.

El Oracle permanece por debajo de DML, pero la distancia entre MLP y el benchmark numérico se reduce de forma sustancial. El resultado establece una traducción económica clara de la mejora de Delta en un problema local de primer orden. Su alcance es limitado a estados interiores del calendario. La dinámica añade rebalanceo y acumulación temporal y evalúa en fronteras de fixing. El cambio simultáneo de diseño y muestra impide atribuir el deterioro a un único componente.

5.7. Cobertura dinámica con forwards

La prueba dinámica rebalancea mensualmente, después de cada fixing, un forward de compute modelizado y de coste inicial nulo. Se comparan no-hedge, Oracle RQMC y los ensembles de cinco semillas MLP y DML entrenados con 65 536 estados. Tras exigir permanencia en el dominio común válido, la evaluación comprende 2 038 trayectorias terminales. El diseño fue fijado antes de observar los resultados y no se aplicó *clipping*, reentrenamiento ni sustitución posterior del instrumento.

Tabla 5.9. Distribución del error terminal en la cobertura dinámica

Estrategia	RMSE	MAE	Mediana $ E_T $	P95 $ E_T $	P99 $ E_T $
Sin cobertura	0,014998	0,011973	0,011046	0,032054	0,046658
Oracle RQMC	0,002311	0,001742	0,001356	0,004684	0,006682
MLP	0,106515	0,035403	0,003345	0,208294	0,460250
DML	0,038698	0,013641	0,002117	0,078235	0,194261

El RMSE produce una ordenación distinta de la cobertura local:

$$RMSE_{\text{Oracle}} < RMSE_0 < RMSE_{\text{DML}} < RMSE_{\text{MLP}}. \quad (5.11)$$

El Oracle reduce el RMSE un 84,6 % frente a no cubrir, lo que demuestra que el mecanismo puede reducir riesgo dentro del entorno modelizado. DML reduce el RMSE 63,7 % frente al MLP, pero permanece por encima del no-hedge. Sin embargo, la mediana absoluta de DML es 0,002117 frente a 0,011046 sin cobertura, y DML obtiene menor $|E_T|$ que el MLP en 70,07 % de

las trayectorias y que el no-hedge en 77,33 %. La aparente contradicción entre comportamiento típico y RMSE se debe a la severidad de la cola: P99 es 0,194261 para DML frente a 0,046658 sin cobertura y 0,460250 para MLP; los máximos alcanzan 0,470193, 0,073272 y 1,683016, respectivamente.

La ventaja de DML en Delta persiste durante los rebalances, como muestra la Figura 5.3: su RMSE de sensibilidad permanece por debajo del MLP en todas las fronteras representadas. Por tanto, el peor RMSE terminal no se explica por una inversión de la jerarquía MLP–DML en Delta.




Figura 5.3. RMSE de Delta frente al benchmark RQMC según el número de fixings futuros en la cobertura dinámica.

La transformación desde Delta a unidades de forward constituye un mecanismo relevante. Si $J_t^F = \partial F_t / \partial P_t$, la posición histórica ejecutada y su desviación respecto a la misma política de referencia son

$$\hat{h}_t = \frac{\hat{\Delta}_t}{J_t^F}, \quad (5.12)$$

$$\hat{h}_t - h_t^* = \frac{\hat{\Delta}_t - \Delta_t^*}{J_t^F}. \quad (5.13)$$

Cuando $|J_t^F|$ es pequeño, errores moderados de Delta pueden amplificarse al convertirse en unidades del instrumento de cobertura. Este mecanismo es compatible con una dinámica fuertemente mean-reverting, pero no identifica causalmente cada trayectoria extrema. El diseño combina rebalanceo discreto, transiciones de fixing y acumulación temporal, sin estimar sus contribuciones causales por separado. El forward se liquida sobre el mismo índice simulado de la asiática: no se introduce un factor de base independiente.

La comparación con el Oracle es esencial: utilizando el mismo calendario y forward, su RMSE de 0,002311 es muy inferior al no-hedge. Por tanto, el resultado de MLP y DML no implica que la cobertura con el forward sea incapaz de funcionar por construcción. A la vez, el forward es un instrumento *modelizado*; el experimento no demuestra liquidez ni disponibilidad

de un contrato real equivalente.

La corrección del descuento de la Ecuación 4.39 se evalúa como diagnóstico posterior sobre las mismas liquidaciones conservadas. Con $r = 0,03$ y $h = 1/12$, multiplica cada posición por $e^{rh} = 1,00250313$. Los RMSE resultantes son 0,002309264 para Oracle, 0,106781890 para MLP y 0,038794595 para DML, frente a los valores históricos 0,002310699, 0,106515000 y 0,038698442. La jerarquía permanece y la omisión no explica las colas. Esta reponderación algebraica conserva estados, Deltas y prima inicial; no sustituye al protocolo original.

En las 24 456 decisiones dinámicas de cada estrategia aparecen 90 Deltas negativas del ensemble DML, 1187 del MLP y ninguna del Oracle. Este diagnóstico no identifica qué parte de la cola causan dichas violaciones.

5.8. Concentración del error en las colas

Para cuantificar cuánto pesa una fracción pequeña de trayectorias en el RMSE se define

$$C_q^{(s)} = \frac{\sum_{i \in \mathcal{T}_{q,s}} E_{i,s}^2}{\sum_{i=1}^N E_{i,s}^2}, \quad (5.14)$$

donde $\mathcal{T}_{q,s}$ contiene el porcentaje q de trayectorias con mayor $|E_{i,s}|$. En las 2 038 trayectorias finales, el peor 1 % representa 21 realizaciones y el peor 5 % unas 102.




Figura 5.4. Concentración del error cuadrático terminal en las trayectorias extremas.

En DML, aproximadamente 45–46 % del error cuadrático total procede del peor 1 % y alrededor del 85 % del peor 5 %. Para MLP las proporciones son aproximadamente 51–52 % y 86 %; para no-hedge, 15 % y 41 %; y para Oracle, 15 % y 36 %. Así, unas 102 trayectorias explican alrededor del 85 % de la suma de errores cuadrados de DML.

Este diagnóstico reconcilia las métricas dinámicas: DML mejora al no-hedge en 77,33 % de las trayectorias y reduce sustancialmente la mediana, pero una fracción muy pequeña de realizaciones adversas domina el RMSE. DML reduce además la severidad de la cola frente al MLP, aunque no la elimina. La evidencia es compatible con la interacción entre error residual de

Delta, posible amplificación por $(J_t^F)^{-1}$, fronteras de fixing y acumulación temporal; no permite atribuir causalmente la cola a uno solo de estos mecanismos.

5.9. Discusión conjunta y robustez

La Tabla 5.10 resume la evidencia que responde a las preguntas del trabajo. El patrón no es de dominancia uniforme, sino de una ventaja diferencial que es débil en pricing, fuerte en Delta y cobertura local, y condicionada por las colas en cobertura dinámica.

Tabla 5.10. Síntesis de los principales resultados de la configuración final

Dimensión	MLP	DML	Interpretación
Precio, test	RMSE = 0,001624	RMSE = 0,001516	DML mejora RMSE, pero MLP obtiene menor MAE: no existe dominancia uniforme.
Delta, test	MAE = 0,000123 RMSE = 0,008528	MAE = 0,000136 RMSE = 0,001817	Ventaja amplia y sistemática de DML en la sensibilidad.
	MAE = 0,001234	MAE = 0,000216	
Cobertura local, shock 1 %	RMSE = $6,69 \times 10^{-6}$	RMSE = $1,06 \times 10^{-6}$	La mejora de Delta se transmite claramente a la neutralización local.
Cobertura dinámica	RMSE = 0,106515	RMSE = 0,038698	DML mejora fuertemente al MLP, pero no supera al no-hedge ($RMSE = 0,014998$) por la severidad de una cola reducida.

La robustez interna procede de varias dimensiones complementarias. En Delta, DML gana las cinco semillas para los cuatro tamaños de entrenamiento y la conclusión se reproduce con etiquetas de referencia de mayor precisión. En cobertura local, la jerarquía Oracle–DML–MLP–no-hedge se mantiene para shocks de 0,5 %, 1 % y 2 % y en los cuatro bloques físicos. Los diagnósticos de fixing y concentración de cola se realizaron sobre modelos congelados y no se utilizaron para modificar el protocolo.

Las conclusiones fuertes son, por tanto, que DML mejora de forma amplia y robusta la Delta y que esa mejora tiene una traducción económica clara en cobertura local. En pricing, la evidencia es mixta; en cobertura dinámica, DML mejora sustancialmente al MLP y el comportamiento típico, pero no domina al no-hedge en RMSE. De aquí se desprende el resultado conceptual principal:

una Delta más precisa no implica automáticamente un hedge dinámico superior.

La eficacia final depende también del instrumento utilizado, del calendario contractual y de la acumulación de errores.

6. Conclusiones

6.1. Síntesis de los resultados principales

Este trabajo ha evaluado la aplicación de *Differential Machine Learning* (DML) a la valoración y cobertura de una opción asiática aritmética sobre capacidad de cómputo, utilizando como exposición económica el coste por GPU-hora. El diseño combina datos observados del mercado H100, una dinámica Log-OU, simulación RQMC y una comparación homogénea entre un MLP convencional y un modelo DML con la misma arquitectura y protocolo de entrenamiento. El objetivo principal ha sido determinar si la información diferencial mejora la aproximación del precio y, especialmente, de la Delta, y si esa mejora se traduce en una reducción efectiva del riesgo de cobertura.

La serie H100 analizada presenta un comportamiento compatible con reversión a la media durante el periodo muestral. La estimación física del Log-OU proporciona $\hat{\kappa}_P = 32,6645$, equivalente a una vida media aproximada de 7,75 días. El bootstrap muestra, sin embargo, una incertidumbre relevante en torno a este parámetro. Por ello, el Log-OU debe interpretarse como una representación parsimoniosa y operativa del entorno de simulación, no como la dinámica verdadera del mercado de compute.

En **pricing**, DML no domina uniformemente al MLP. Con 65 536 estados de entrenamiento, DML obtiene un RMSE de test de 0,001516 frente a 0,001624 del MLP, mientras que el MLP presenta un MAE ligeramente inferior. En el conjunto de referencia, construido con etiquetas RQMC de mayor precisión, DML obtiene una ventaja más clara, especialmente en RMSE. La conclusión adecuada es, por tanto, que DML mantiene una precisión de precio comparable y mejora algunas métricas, pero no ofrece una superioridad general en valoración.

La evidencia es mucho más concluyente para la **Delta**. En la configuración final, el RMSE disminuye de 0,008528 con MLP a 0,001817 con DML y el MAE de 0,001234 a 0,000216. Esto equivale a reducciones emparejadas medias próximas al 78,5 % y al 82,0 %, respectivamente. DML obtiene además menor MAE y RMSE de Delta en las cinco semillas y en todos los tamaños de entrenamiento considerados, patrón que también se reproduce sobre el conjunto de referencia. La principal evidencia empírica del trabajo es, por tanto, una mejora amplia, consistente y robusta de la sensibilidad cuando se incorpora supervisión diferencial.

Los resultados muestran también una mayor **eficiencia muestral** dentro de la malla experimental: DML entrenado con 1 024 estados supera al MLP con 16 384 en MAE y RMSE de Delta. Este resultado no permite establecer una ratio universal de eficiencia, pero sí indica que las derivadas aportan información adicional útil por estado simulado. Esta ventaja no implica menor coste computacional total, ya que el entrenamiento diferencial es más costoso que el convencional.

El análisis de errores extremos refuerza esta conclusión y, al mismo tiempo, identifica

una debilidad concreta. Los mayores errores de Delta se concentran desproporcionadamente cerca de las fronteras mensuales de fixing: la distancia mediana al fixing más próximo es de aproximadamente 0,49 días entre los cincuenta mayores errores de DML, frente a 7,54 días en la muestra completa. Esta evidencia sugiere que la representación temporal utilizada captura de forma imperfecta los cambios discretos del estado contractual.

La utilidad económica de la Delta aprendida se confirma claramente en la **cobertura local**. Para un shock del 1 %, el RMSE del residuo pasa de $6,6878 \times 10^{-6}$ con MLP a $1,0584 \times 10^{-6}$ con DML, una mejora aproximada del 84,2 %; frente a la posición sin cobertura, la reducción supera el 99 %. El mismo orden se mantiene para shocks del 0,5 % y del 2 %. En este entorno, una mejor estimación de la sensibilidad se traduce directamente en una mejor neutralización del riesgo de primer orden.

La **cobertura dinámica** introduce una conclusión más exigente. DML sigue siendo muy superior al MLP, con RMSE terminal de 0,038698 frente a 0,106515, y obtiene menor error absoluto que el MLP en el 70,07 % de las trayectorias. También mejora frente a no cubrir en el 77,33 % de las trayectorias y reduce notablemente la mediana del error absoluto. Sin embargo, su RMSE permanece por encima del 0,014998 de la posición sin cobertura. El benchmark Oracle, con RMSE próximo a 0,0023, confirma que el esquema de hedge puede reducir riesgo dentro del modelo; el deterioro de los modelos aprendidos procede de una pequeña fracción de trayectorias extremas que domina el error cuadrático agregado.

En conjunto, el resultado central del TFM es que **DML mejora de forma sustancial la Delta y esa mejora posee valor económico en cobertura local, pero una Greek más precisa no garantiza por sí sola una mejor cobertura dinámica**. La eficacia final depende también del instrumento utilizado, de su sensibilidad al spot, del rebalanceo discreto, del estado contractual y del comportamiento de las colas.

6.2. Respuesta a las preguntas de investigación

La primera pregunta recibe una respuesta diferenciada: la supervisión de Delta mejora de forma consistente la sensibilidad, mientras que su efecto sobre el precio depende de la métrica y del conjunto evaluado. La segunda recibe una respuesta condicionada por el uso: la ventaja se transmite al residuo local, pero no basta para superar a no cubrir en RMSE terminal con la política dinámica ejecutada. Estos resultados delimitan cuándo resulta útil añadir información diferencial.

6.3. Implicaciones financieras y aportación

Los resultados sugieren que la evaluación de un surrogate para derivados no debería limitarse al error de precio cuando su uso posterior depende de las Greeks. Dos modelos pueden presentar errores de valoración similares y, sin embargo, ofrecer una calidad muy distinta para gestión del riesgo. En este TFM, esa diferencia es precisamente la principal ventaja de DML: la

incorporación de información diferencial apenas altera la conclusión sobre pricing, pero mejora de forma sustancial la sensibilidad relevante para cobertura.

La segunda implicación es que la eficiencia muestral debe distinguirse de la eficiencia computacional. Las etiquetas diferenciales permiten extraer más estructura de cada estado simulado y alcanzar una mejor precisión de Delta con menos observaciones dentro del experimento realizado. Sin embargo, el entrenamiento DML requiere un coste adicional. La utilidad del método dependerá, por tanto, de que las derivadas puedan obtenerse de forma fiable y de que las sensibilidades tengan suficiente importancia económica para justificar dicho coste.

La comparación entre cobertura local y dinámica aporta una tercera implicación. Una mejor Delta constituye una condición favorable para el hedge, pero no suficiente. En la estrategia dinámica la sensibilidad debe transformarse en unidades de un forward modelizado mediante su Jacobiano respecto al spot; bajo fuerte reversión a la media, un Jacobiano reducido puede amplificar errores residuales de Delta. El diseño combina además rebalanceo discreto y transiciones de fixing, sin identificar contribuciones causales separadas ni un factor de base independiente. Por este motivo, la calidad de una Greek debe evaluarse conjuntamente con el mecanismo mediante el que se convierte en una posición económica.

Finalmente, el trabajo muestra que el coste por GPU-hora puede formularse como una exposición cuantitativa susceptible de modelización mediante un payoff dependiente del promedio. Esto no implica que exista actualmente un mercado líquido y estandarizado de derivados sobre compute ni que los precios obtenidos constituyan cotizaciones implementables. La aportación es metodológica: integrar datos de compute, una dinámica estocástica, valoración RQMC, aprendizaje de precio y Delta, y evaluación de cobertura dentro de un protocolo común que permite identificar con precisión dónde DML aporta valor y dónde esa ventaja deja de ser suficiente.

6.4. Limitaciones

La principal limitación procede de los **datos**. La serie H100 utilizada contiene 92 observaciones diarias entre el 26 de mayo y el 25 de agosto de 2026. Esta historia es suficiente para una primera caracterización, pero corta para establecer la estabilidad de largo plazo de la reversión a la media. El bootstrap confirma una incertidumbre apreciable en κ_P . Además, las referencias de Ornn y SMM no corresponden a contratos idénticos y sólo permiten una comparación descriptiva entre mercados. H100 tampoco representa de forma exhaustiva el conjunto del mercado de capacidad computacional.

La segunda limitación afecta a la **especificación del subyacente**. El Log-OU de un factor proporciona positividad, reversión a la media y transición exacta, pero excluye volatilidad estocástica, saltos, estacionalidad, factores tecnológicos o regionales y posibles cambios de régimen. En consecuencia, el experimento identifica con precisión el error de aproximación de MLP y DML respecto a la función definida por el modelo, pero no cuantifica el error de especificación que existiría frente a un futuro mercado real.

Una tercera limitación es la **identificación de la medida de valoración**. Al no existir una historia suficientemente líquida de forwards y opciones sobre GPU-hour que permita inferir una medida neutral al riesgo de mercado, los parámetros utilizados bajo $\mathbb{Q}$ son una especificación modelizada. Las bandas empleadas no deben interpretarse como intervalos de confianza de parámetros neutrales al riesgo y los precios sintéticos no equivalen a cotizaciones observables. Esta restricción afecta al nivel absoluto de valoración, aunque menos a la comparación interna entre MLP y DML, que utilizan la misma ley de pricing y las mismas etiquetas.

La cuarta limitación reside en la **representación del estado contractual**. El vector de entrada incorpora el tiempo a vencimiento y el promedio acumulado, pero no variables explícitas como el número de fixings pendientes o la distancia al siguiente fixing. Con el calendario fijo, τ determina ya esos metadatos: explicitarlos facilita la representación, sin añadir información. La concentración de errores extremos cerca de estas fronteras sugiere que una red suave debe aprender implícitamente cambios contractuales discretos a partir de una variable temporal continua. El diagnóstico fue realizado después de congelar los modelos y no se utilizó para reentrenarlos, preservando la validez de la evaluación final.

La salida neuronal tampoco garantiza precio no negativo ni monotonidad respecto al spot. Las violaciones observadas se documentan sin recorte retrospectivo; una arquitectura restringida deberá contrastarse con un nuevo test. Además, las pruebas local y dinámica cambian la distribución temporal evaluada (estados interiores frente a fronteras), por lo que su comparación no aísla el efecto del rebalanceo. La muestra dinámica es condicional a permanecer en el dominio y la dispersión entre semillas sólo recoge variación del entrenamiento sobre los mismos datos.

La quinta limitación afecta al **instrumento de cobertura**. El forward de compute utilizado es modelizado y no incorpora directamente bid–ask, liquidez, costes de ejecución, margen o límites de posición. Además, su sensibilidad al spot puede ser pequeña bajo reversión a la media, amplificando errores de Delta al convertirlos en unidades de hedge. La corrección de descuento del ratio forward se presenta como diagnóstico posterior y no altera la jerarquía de RMSE. Por ello, los resultados dinámicos deben interpretarse como evidencia dentro del entorno modelizado y no como estimación directa del rendimiento de una estrategia negociable.

En síntesis, la comparación MLP–DML posee una validez interna elevada porque ambos modelos comparten datos, función de valoración y protocolo. La validez externa del nivel de precios y de la cobertura dinámica es más limitada y depende de la representatividad de los datos, de la especificación de $\mathbb{Q}$ y de la existencia futura de instrumentos observables sobre compute.

6.5. Líneas futuras de investigación

Las extensiones prioritarias deben responder directamente a las limitaciones identificadas. La primera es enriquecer el estado contractual con variables explícitas como N_{future} y d_{fix}

y comprobar, sobre un nuevo conjunto de test, si reducen la concentración de errores alrededor de los fixings. La segunda es reestimar la dinámica a medida que se disponga de una historia H100 más extensa y evaluar la estabilidad temporal de κ , θ y σ antes de introducir modelos más complejos.

Una tercera extensión consiste en sustituir progresivamente el forward modelizado por instrumentos observables cuando exista suficiente liquidez, incorporando precios de mercado, costes de transacción y riesgo de base real. Esos instrumentos permitirían además identificar mejor la dinámica de valoración y contrastar precios modelizados con cotizaciones efectivas.

Sólo después de disponer de una base empírica más rica tendría sentido ampliar el Log-OU a especificaciones multifactoriales, estudiar otras GPUs o regiones y comparar el enfoque actual con estrategias de *Deep Hedging* que aprendan directamente la política de cobertura. La prioridad no es añadir complejidad algorítmica, sino resolver primero las limitaciones de datos, estado e instrumentación que los propios resultados han puesto de manifiesto.

Declaración de uso de herramientas de inteligencia artificial

En la elaboración de este trabajo se utilizaron ChatGPT y Codex como herramientas de apoyo para la revisión de redacción, creación y depuración de código, comprobaciones de coherencia y revisión de fórmulas y resultados. La revisión final con Codex se realizó con asistencia basada en GPT-6; no se conserva un registro completo de las versiones utilizadas en las consultas anteriores de ChatGPT. Todos los resultados, referencias, fórmulas y procedimientos fueron revisados y verificados por el autor, que asume íntegramente la responsabilidad sobre el contenido final.

Referencias

- Amazon Web Services. (s.f.-a). *Amazon EC2 on-demand instances*. Consultado el 1 de septiembre de 2026, desde <https://docs.aws.amazon.com/AWSEC2/latest/UserGuide/ec2-on-demand-instances.html>
- Amazon Web Services. (s.f.-b). *Amazon EC2 reserved instances*. Consultado el 1 de septiembre de 2026, desde <https://docs.aws.amazon.com/AWSEC2/latest/UserGuide/ec2-reserved-instances.html>
- Anderson, R. W., & Danthine, J.-P. (1981). Cross hedging. *Journal of Political Economy*, 89(6), 1182-1196. <https://doi.org/10.1086/261028>
- Bandi, F. M., & Su, Y. (2026). (Early) AI compute asset pricing [Working paper; SSRN version revised August 2026]. <https://doi.org/10.2139/ssrn.7034058>
- Baydin, A. G., Pearlmutter, B. A., Radul, A. A., & Siskind, J. M. (2018). Automatic differentiation in machine learning: A survey. *Journal of Machine Learning Research*, 18(153), 1-43. Consultado el 7 de septiembre de 2026, desde <https://www.jmlr.org/papers/v18/17-468.html>
- Bessembinder, H., Coughenour, J. F., Seguin, P. J., & Smoller, M. M. (1995). Mean reversion in equilibrium asset prices: Evidence from the futures term structure. *The Journal of Finance*, 50(1), 361-375. <https://doi.org/10.1111/j.1540-6261.1995.tb05178.x>
- Bessembinder, H., & Lemmon, M. L. (2002). Equilibrium pricing and optimal hedging in electricity forward markets. *The Journal of Finance*, 57(3), 1347-1382. <https://doi.org/10.1111/1540-6261.00463>
- Black, F., & Scholes, M. (1973). The pricing of options and corporate liabilities. *Journal of Political Economy*, 81(3), 637-654. <https://doi.org/10.1086/260062>
- Boyle, P. P. (1977). Options: A Monte Carlo approach. *Journal of Financial Economics*, 4(3), 323-338. [https://doi.org/10.1016/0304-405X\(77\)90005-8](https://doi.org/10.1016/0304-405X(77)90005-8)
- Boyle, P. P., & Emanuel, D. (1980). Discretely adjusted option hedges. *Journal of Financial Economics*, 8(3), 259-282. [https://doi.org/10.1016/0304-405X\(80\)90003-3](https://doi.org/10.1016/0304-405X(80)90003-3)
- Broadie, M., & Glasserman, P. (1996). Estimating security price derivatives using simulation. *Management Science*, 42(2), 269-285. <https://doi.org/10.1287/mnsc.42.2.269>
- Caflish, R. E. (1998). Monte Carlo and Quasi-Monte Carlo methods. *Acta Numerica*, 7, 1-49. <https://doi.org/10.1017/S0962492900002804>
- Cartea, Á., & Figueroa, M. G. (2005). Pricing in electricity markets: A mean reverting jump diffusion model with seasonality. *Applied Mathematical Finance*, 12(4), 313-335. <https://doi.org/10.1080/13504860500117503>
- CME Group. (2026, 11 de agosto). *CME Group and Silicon Data to launch compute futures on October 5 to unlock new way to hedge AI risks* [Launch announced for 5 October 2026, pending regulatory review]. Consultado el 7 de septiembre de 2026, desde <https://www>

- .cmegroup.com/media-room/press-releases/2026/8/11/cme_group_and_silicondataatola
unchcomputeuturesonoctober5tounloc.html
- Commodity Futures Trading Commission. (2026, 19 de agosto). *CFTC requests comment on the listing of compute derivatives contracts* [Press Release No. 9286-26]. Consultado el 1 de septiembre de 2026, desde <https://www.cftc.gov/PressRoom/PressReleases/9286-26>
- Curran, M. (1994). Valuing Asian and portfolio options by conditioning on the geometric mean price. *Management Science*, 40(12), 1705-1711. <https://doi.org/10.1287/mnsc.40.12.1705>
- Ederington, L. H. (1979). The hedging performance of the new futures markets. *The Journal of Finance*, 34(1), 157-170. <https://doi.org/10.1111/j.1540-6261.1979.tb02077.x>
- Efron, B., & Tibshirani, R. J. (1993). *An introduction to the bootstrap* (Vol. 57). Chapman & Hall.
- Gibson, R., & Schwartz, E. S. (1990). Stochastic convenience yield and the pricing of oil contingent claims. *The Journal of Finance*, 45(3), 959-976. <https://doi.org/10.1111/j.1540-6261.1990.tb05114.x>
- Glasserman, P. (2004). *Monte Carlo methods in financial engineering* (Vol. 53). Springer. <https://doi.org/10.1007/978-0-387-21617-1>
- Google Cloud. (s.f.-a). *Resource-based committed use discounts*. Consultado el 1 de septiembre de 2026, desde <https://cloud.google.com/compute/docs/instances/signing-up-committed-use-discounts>
- Google Cloud. (s.f.-b). *Spot VMs*. Consultado el 1 de septiembre de 2026, desde <https://cloud.google.com/compute/docs/instances/spot>
- He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 770-778. <https://doi.org/10.1109/CVPR.2016.90>
- Hornik, K., Stinchcombe, M., & White, H. (1989). Multilayer feedforward networks are universal approximators. *Neural Networks*, 2(5), 359-366. [https://doi.org/10.1016/0893-6080\(89\)90020-8](https://doi.org/10.1016/0893-6080(89)90020-8)
- Horvath, B., Muguruza, A., & Tomas, M. (2021). Deep learning volatility: A deep neural network perspective on pricing and calibration in (rough) volatility models. *Quantitative Finance*, 21(1), 11-27. <https://doi.org/10.1080/14697688.2020.1817974>
- Huge, B., & Savine, A. (2020). Differential machine learning [Extended methodological version; related article published in Risk in 2020]. <https://doi.org/10.48550/arXiv.2005.02347>
- Hutchinson, J. M., Lo, A. W., & Poggio, T. (1994). A nonparametric approach to pricing and hedging derivative securities via learning networks. *The Journal of Finance*, 49(3), 851-889. <https://doi.org/10.1111/j.1540-6261.1994.tb00081.x>
- International Energy Agency. (2025, 10 de abril). *Energy and AI*. International Energy Agency. Consultado el 1 de septiembre de 2026, desde <https://www.iea.org/reports/energy-and-ai>

- Kemna, A. G. Z., & Vorst, A. C. F. (1990). A pricing method for options based on average asset values. *Journal of Banking & Finance*, 14(1), 113-129. [https://doi.org/10.1016/0378-4266\(90\)90039-5](https://doi.org/10.1016/0378-4266(90)90039-5)
- Leland, H. E. (1985). Option pricing and replication with transactions costs. *The Journal of Finance*, 40(5), 1283-1301. <https://doi.org/10.1111/j.1540-6261.1985.tb02383.x>
- Li, Z., Zhang, H., O'Brien, L., Jiang, S., Zhou, Y., Kihl, M., & Ranjan, R. (2016). Spot pricing in the cloud ecosystem: A comparative investigation. *Journal of Systems and Software*, 114, 1-19. <https://doi.org/10.1016/j.jss.2015.10.042>
- Lin, L., Pan, L., & Liu, S. (2022). Methods for improving the availability of spot instances: A survey. *Computers in Industry*, 141, 103718. <https://doi.org/10.1016/j.compind.2022.103718>
- Liu, S., Oosterlee, C. W., & Bohte, S. M. (2019). Pricing options and computing implied volatilities using neural networks. *Risks*, 7(1), 16. <https://doi.org/10.3390/risks7010016>
- Lucia, J. J., & Schwartz, E. S. (2002). Electricity prices and power derivatives: Evidence from the Nordic Power Exchange. *Review of Derivatives Research*, 5(1), 5-50. <https://doi.org/10.1023/A:1013846631785>
- Merton, R. C. (1973). Theory of rational option pricing. *The Bell Journal of Economics and Management Science*, 4(1), 141-183. <https://doi.org/10.2307/3003143>
- NVIDIA Corporation. (s.f.). *NVIDIA H100 Tensor Core GPU*. Consultado el 1 de septiembre de 2026, desde <https://www.nvidia.com/en-us/data-center/h100/>
- Ornn. (2026). *Ornn compute price index: API Documentation*. Consultado el 1 de septiembre de 2026, desde <https://index.ornn.com/docs>
- Ornn Data LLC. (2026a). *Frequently asked questions*. Consultado el 1 de septiembre de 2026, desde <https://data.ornn.com/faq>
- Ornn Data LLC. (2026b). *GPU market prices — compute price index (OCPI)*. Consultado el 1 de septiembre de 2026, desde <https://data.ornn.com/markets>
- Ornn Data LLC. (2026c, 24 de julio). *Ornn compute price indices (OCPI): Methodology*. Consultado el 1 de septiembre de 2026, desde <https://data.ornn.com/methodology>
- Owen, A. B. (1997). Scrambled net variance for integrals of smooth functions. *The Annals of Statistics*, 25(4), 1541-1562. <https://doi.org/10.1214/aos/1031594731>
- Rogers, L. C. G., & Shi, Z. (1995). The value of an Asian option. *Journal of Applied Probability*, 32(4), 1077-1088. <https://doi.org/10.2307/3215221>
- Ruf, J., & Wang, W. (2020). Neural networks for option pricing and hedging: A literature review. *Journal of Computational Finance*, 24(1), 1-46. <https://doi.org/10.21314/JCF.2020.390>
- Sánchez Sánchez, M. (2026). Módulo 7: Valoración de instrumentos financieros [Máster en Finanzas Cuantitativas, curso 2025/2026].
- Schwartz, E. S. (1997). The stochastic behavior of commodity prices: Implications for valuation and hedging. *The Journal of Finance*, 52(3), 923-973. <https://doi.org/10.1111/j.1540-6261.1997.tb02721.x>

- Sevilla, J., Heim, L., Ho, A., Besiroglu, T., Hobbhahn, M., & Villalobos, P. (2022). Compute trends across three eras of machine learning. *2022 International Joint Conference on Neural Networks (IJCNN)*, 1-8. <https://doi.org/10.1109/IJCNN55064.2022.9891914>
- Shanghai Metals Market. (2026a, 25 de junio). *[SMM announcement] launch of SMM GPU cloud compute spot price index & SMM GPU cloud compute spot listing price* [Announcement of the two GPU cloud compute price series, effective 3 July 2026]. Consultado el 7 de septiembre de 2026, desde <https://www.metal.com/announcements/103972680-smm-announcement-launch-of-smm-gpu-cloud-compute-spot-price-index-smm-gpu-cloud-compute-spot-listing-price>
- Shanghai Metals Market. (2026b). *H100 computing power price series — Yangtze River Delta* [Serie SMM-GPU-CC-005; extracción del 26/08/2026 conservada en data/raw/china]. Consultado el 1 de septiembre de 2026, desde <https://price.smm.cn/>
- Shanghai Metals Market. (2026c). *SMM historical prices: Computing power* [Series SMM-GPU-CC-019 y SMM-GPU-CC-005; extracción del 26/08/2026 conservada en data/raw/china]. Consultado el 1 de septiembre de 2026, desde <https://price.smm.cn/>
- Sobol', I. M. (1967). On the distribution of points in a cube and the approximate evaluation of integrals. *USSR Computational Mathematics and Mathematical Physics*, 7(4), 86-112. [https://doi.org/10.1016/0041-5553\(67\)90144-9](https://doi.org/10.1016/0041-5553(67)90144-9)
- Stanford Institute for Human-Centered Artificial Intelligence. (2026). *The 2026 AI index report*. Stanford University. Consultado el 1 de septiembre de 2026, desde <https://hai.stanford.edu/ai-index/2026-ai-index-report>
- Turnbull, S. M., & Wakeman, L. M. (1991). A quick algorithm for pricing European average options. *Journal of Financial and Quantitative Analysis*, 26(3), 377-389. <https://doi.org/10.2307/2331213>
- Uhlenbeck, G. E., & Ornstein, L. S. (1930). On the theory of the Brownian motion. *Physical Review*, 36(5), 823-841. <https://doi.org/10.1103/PhysRev.36.823>
- Wu, C., Buyya, R., & Ramamohanarao, K. (2019). Cloud pricing models: Taxonomy, survey, and interdisciplinary challenges. *ACM Computing Surveys*, 52(6), 1-36. <https://doi.org/10.1145/3342103>
- Xu, H., & Li, B. (2013). Dynamic cloud pricing for revenue maximization. *IEEE Transactions on Cloud Computing*, 1(2), 158-171. <https://doi.org/10.1109/TCC.2013.15>